

26-2 DSL 정규 세션

Part 1 과제



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시요. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P 는 직교행렬, D 는 고윳값 대각행렬)

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

$$A - \lambda I = \begin{bmatrix} 4-\lambda & 2 \\ 2 & 1-\lambda \end{bmatrix} \quad \begin{aligned} (4-\lambda)(1-\lambda) - 4 &= 0 \\ \lambda^2 - 5\lambda &= 0 \end{aligned}$$

$$i) \lambda = 5$$

$$\begin{bmatrix} -1 & 2 \\ 2 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\begin{aligned} -x_1 + 2x_2 &= 0 \\ 2x_1 - 4x_2 &= 0 \end{aligned} \quad \rightarrow x_1 = 2x_2$$

$$v_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \|v_1\| = \sqrt{5}$$

$$\therefore \lambda_1 = 5, \quad u_1 = \begin{bmatrix} \frac{2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \end{bmatrix}$$

$$ii) \lambda = 0$$

$$\begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$4x_1 + 2x_2 = 0 \quad \rightarrow x_2 = -2x_1$$

$$v_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \quad \|v_2\| = \sqrt{5}$$

$$\therefore \lambda_2 = 0, \quad u_2 = \begin{bmatrix} \frac{1}{\sqrt{5}} \\ -\frac{2}{\sqrt{5}} \end{bmatrix}$$

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P 는 직교행렬, D 는 고윳값 대각행렬)

$$P = \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix} \quad D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \quad P^T = P$$

$$PD = \begin{bmatrix} 2\sqrt{5} & 0 \\ \sqrt{5} & 0 \end{bmatrix} \quad PDP^T = \begin{bmatrix} 2\sqrt{5} & 0 \\ \sqrt{5} & 0 \end{bmatrix} \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix} = A$$

$$\therefore A = \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

→ 모든 고윳값 ≥ 0 이므로 PSD

$$\begin{aligned} x^T A x &= [x_1 \ x_2] \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= [x_1 \ x_2] \begin{bmatrix} 4x_1 + 2x_2 \\ 2x_1 + x_2 \end{bmatrix} \\ &= 4x_1^2 + 4x_1x_2 + x_2^2 \\ &= (2x_1 + x_2)^2 \geq 0 \end{aligned}$$

PD	고윳값 > 0	모든 $x \neq 0$ 에 대해 $x^T A x > 0$
PSD	≥ 0	모든 x 에 대해 $x^T A x \geq 0$
ND	< 0	모든 $x \neq 0$ 에 대해 $x^T A x < 0$
NSD	≤ 0	모든 x 에 대해 $x^T A x \leq 0$

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

고유벡터의 성질 : $Av = \lambda v$ 만족 $\rightarrow$ 서로 다른 고유벡터들끼리 내적이 0이어야 한다는 것 X

A가 대칭행렬인 경우,

$$Av = \lambda v, \quad Aw = \mu w \quad (\lambda \neq \mu)$$

$$v^T (Aw) = v^T (\mu w)$$

$$\rightarrow (Av)^T w = \mu v^T w$$

$$\rightarrow (\lambda v)^T w = \mu v^T w$$

$$\rightarrow \lambda v^T w = \mu v^T w$$

$$(\mu - \lambda) v^T w = 0$$

$$\lambda \neq \mu \text{ 이므로 } \mu - \lambda \neq 0 \quad \therefore v^T w = 0$$

→ 실수 대칭행렬에서 서로 다른 고윳값의 고유벡터는 서로 직교한다

* $B^T B$ 과 BB^T 의 특징

$$B^T B v = \lambda v$$

$$BB^T B v = \lambda B v$$

$$BB^T (Bv) = \lambda (Bv)$$

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} \quad \begin{array}{l} Bv \neq 0 \text{ 이면} \\ Bv \text{ 는 } BB^T \text{의 레벤키터, 고윳값은 똑같이 } \lambda \end{array}$$

1) $B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3개 나오며, 그중 가장 작은 고윳값은 0이 됩니다.)

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U \Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0인 3×2 직사각 대각행렬입니다.)

BB^T 의 단위 고유벡터들 $B^T B$ 의 단위 고유벡터들

$$SVD : B = U \Sigma V^T$$

특잇값(singular value)을 대각선에 넣는 행렬

$$\text{특잇값 } \sigma_i = \sqrt{B^T B \text{의 레벤키트 } \lambda_i}$$

$$\left(\xrightarrow{V^T} \text{방향 회전} \xrightarrow{\Sigma} \text{축별 크기 조절 (늘리기/줄이기)} \xrightarrow{U} \text{다시 방향 회전} \right)$$

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1) $B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

$$B^T B = \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix}$$

$$BB^T = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

$$B^T B - \lambda I = \begin{bmatrix} 9-\lambda & 7 \\ 7 & 9-\lambda \end{bmatrix}$$

$$(9-\lambda)^2 - 49 = 0$$

$$\lambda^2 - 18\lambda + 32 = 0$$

$$(\lambda-2)(\lambda-16) = 0$$

$$i) \lambda = 2$$

$$ii) \lambda = 16$$

$$\begin{bmatrix} 7 & 7 \\ 7 & 7 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

$$x_1 = -x_2 \rightarrow \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\therefore \lambda_1 = 2, \quad v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\begin{bmatrix} -7 & 7 \\ 7 & -7 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

$$x_1 = x_2 \rightarrow \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\therefore \lambda_2 = 16, \quad v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\Rightarrow V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}, \quad \sigma_1 = 4, \quad \sigma_2 = \sqrt{2}$$

($\sigma_1 > \sigma_2$)

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3개 나오며, 그중 가장 작은 고윳값은 0이 됩니다.)

B^TB 와 BB^T 의 eigen value는 동일

$$\therefore \lambda_1 = 16 \quad \lambda_2 = 2 \quad \lambda_3 = 0$$

i) $\lambda_1 = 16$

$$\begin{bmatrix} -8 & 0 & 8 \\ 0 & -14 & 0 \\ 8 & 0 & -8 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0$$

$$\begin{aligned} -8x_1 + 8x_3 &= 0 \\ -14x_2 &= 0 \\ \therefore x_2 &= 0, \quad x_1 = x_3 \end{aligned}$$

$$\rightarrow \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \therefore u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

ii) $\lambda_2 = 2$

$$\begin{bmatrix} 6 & 0 & 8 \\ 0 & 0 & 0 \\ 8 & 0 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0$$

$$\begin{aligned} 6x_1 + 8x_3 &= 0 \\ 8x_1 + 6x_3 &= 0 \\ \therefore x_1 &= x_3 = 0 \end{aligned}$$

$$\therefore u_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

iii) $\lambda_3 = 0$

$$\begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 0$$

$$\begin{aligned} 8x_1 + 8x_3 &= 0 \\ 2x_2 &= 0 \\ \therefore x_1 &= -x_3, \quad x_2 = 0 \end{aligned}$$

$$\rightarrow \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} \therefore u_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

$$\Rightarrow V = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U\Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0인 3×2 직사각 대각행렬입니다.)

$$B = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

공분산행렬의 고유벡터 = 주성분방향

고유값 = 그 방향으로 데이터가 퍼진 정도(분산)
→ 큰 고유값부터 PC1, PC2, ...

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

- 1) Σ 의 고유값과 각 고유값에 대응하는 단위 고유벡터를 구하세요.
- 2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.
(💡 힌트: PCA에서는 가장 큰 고유값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고유값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)
- 3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.
- 4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1) Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

$$\Sigma - \lambda I = \begin{bmatrix} 5-\lambda & 3 \\ 3 & 5-\lambda \end{bmatrix}$$

$$\begin{aligned} (5-\lambda)^2 - 9 &= 0 \\ \lambda^2 - 10\lambda + 16 &= 0 \\ (\lambda-2)(\lambda-8) &= 0 \end{aligned}$$

i) $\lambda_1 = 8$

$$\begin{bmatrix} -3 & 3 \\ 3 & -3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

$$-3x_1 + 3x_2 = 0$$

$$x_1 = x_2 \rightarrow \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\therefore V_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

= PC1 방향벡터

ii) $\lambda_2 = 2$

$$\begin{bmatrix} 3 & 3 \\ 3 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

$$3x_1 + 3x_2 = 0$$

$$x_1 = -x_2 \rightarrow \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\therefore V_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

= PC2 방향벡터

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

$$PC1: \frac{8}{8+2} = 0.8$$

$$PC2: \frac{2}{8+2} = 0.2$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

20%, PC2가 설명하던 분산비율을 잃기 때문

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

$$P(A) = \frac{8}{16} = 0.5, \quad P(B) = \frac{4}{16} = 0.25, \quad P(C) = \frac{4}{16} = 0.25$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

$$H(X) = -\left[\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{4} \log_2 \frac{1}{4} + \frac{1}{4} \log_2 \frac{1}{4}\right] = -\left[-\frac{1}{2} - \frac{1}{2} - \frac{1}{2}\right] = \frac{3}{2} = 1.5 \text{ bits}$$

3) 엔트로피의 최댓값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$H_{\max} = -\left[\frac{1}{3} \log_2 \frac{1}{3} \times 3\right] = \log_2 3 \approx 1.585 \text{ bits}$$

2-2: KL-Divergence

두 확률 분포 P 와 Q 가 다음과 같이 주어졌습니다.

X	A	B	C
$P(X)$	0.5	0.3	0.2
$Q(X)$	0.25	0.5	0.25

1) $D_{KL}(P||Q)$ 와 $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence 가

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

$$D_{KL}(P||Q) = 0.5 \log_2 \frac{0.5}{0.25} + 0.3 \log_2 \frac{0.3}{0.5} + 0.2 \log_2 \frac{0.2}{0.25} \approx 0.5 - 0.221 - 0.064 \approx 0.215 \text{ bits}$$

$$D_{KL}(Q||P) = 0.25 \log_2 \frac{0.25}{0.5} + 0.5 \log_2 \frac{0.5}{0.3} + 0.25 \log_2 \frac{0.25}{0.2} \approx -0.25 + 0.3685 + 0.0805 \approx 0.199 \text{ bits}$$

2) KL Divergence 의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

$$\therefore \text{KL-div} = 0 \text{ 일 때는 분포가 같을 때 } (P(x) = Q(x))$$

$$D_{KL}(P||Q) = \sum_x P(x) \log_2 P(x) - \sum_x P(x) \log_2 Q(x)$$

26-2 Part 1 과제

$$= -\text{entropy} = \text{cross entropy}$$

$$\Rightarrow \text{cross entropy} = \text{entropy} + \text{KL Divergence}$$

3. Regression

3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 (n=5).

x	1	2	3	4	5
y	2	3	5	6	9

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

$$\bar{x}=3, \bar{y}=5, S_{xy} = 6+2+0+1+8=17, S_{xx} = 4+1+0+1+4=10$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

$$\hat{\beta}_1 = \frac{17}{10} = 1.7, \hat{\beta}_0 = 5 - 1.7 \times 3 = -0.1, \hat{y} = -0.1 + 1.7x$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

$$\hat{y} = (1.6, 3.3, 5.0, 6.7, 8.4) \quad SSE = 0.16 + 0.09 + 0 + 0.49 + 0.36 = 1.1 \dots \text{회귀선 오차의 분산}$$

$$e = (0.4, -0.3, 0, -0.1, 0.6) \quad SST = 9 + 4 + 0 + 1 + 16 = 30 \dots \text{4 데이터의 잔차 분산}$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

4개의 잔차 분산 중 약 96.3%를 설명한다.

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.1}{30} = 1 - 0.03666 \dots \approx 0.963$$

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해 X_1 의 VIF 를 계산하세요.

$$VIF_j = \frac{1}{1 - R_j^2} = \frac{1}{1 - 0.9} = 10$$

2) 위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

X_1 은 X_2, X_3 와 강한 다중공선성을 보임 $\rightarrow$ 변수의 독립성 증대성 때문 변수의 중복성, 모델 성능 등을 함께 고려한다면 제거 가능

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3.5,4)
Class B (○): (5,5), (5,3), (6,4)

새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN 으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요

$$d(q, (1,1)) = 3\sqrt{2} \approx 4.243, \quad d(q, (3.5,4)) = 0.5$$

$$d(q, (5,5)) = \sqrt{2} \approx 1.414, \quad d(q, (5,3)) = \sqrt{2} \approx 1.414, \quad d(q, (6,4)) = 2$$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

$\therefore \text{class B}$

3) 거리의 역수 $w_i = \frac{1}{d(X_q, X_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

$$W_A = \frac{1}{0.5} = 2, \quad W_B = \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} = \sqrt{2} \approx 1.414 \quad \therefore \text{class A}$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

'이웃수'만 중요 '이웃의거리'도 중요

A점 하나가 9칸 해우 가깝게 때문에, B 이웃 5개의 가중치 합보다
A의 가중치 하나가 더 커짐

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)

초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

$$P_1 \rightarrow C_1, P_2 \rightarrow C_1, P_3 \rightarrow C_1, P_4 \rightarrow C_2, P_5 \rightarrow C_2, P_6 \rightarrow C_2$$

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

$$C'_1 = \left(\frac{2+2+3}{3}, \frac{3+1+2}{3} \right) = \left(\frac{7}{3}, 2 \right), \quad C'_2 = \left(\frac{8+9+8}{3}, \frac{8+8+9}{3} \right) = \left(\frac{25}{3}, \frac{25}{3} \right)$$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

$$P_1 \rightarrow C'_1, P_2 \rightarrow C'_1, P_3 \rightarrow C'_1, P_4 \rightarrow C'_2, P_5 \rightarrow C'_2, P_6 \rightarrow C'_2$$

이전배정과 재배정 결과가 같으므로 k-means 알고리즘이 수렴한다.

5-2: DBSCAN

다음과 같은 2 차원 데이터에 $\text{eps} = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

$P1(1,1)$, $P2(1,2)$, $P3(2,1)$, $P4(2,2)$, $P5(8,8)$, $P6(8,9)$, $P7(10,8)$, $P8(9,8)$, $P9(12,12)$

1) 각 점에 대해 eps 반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가 eps 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)


$P_1, P_2, P_3, P_4 \rightarrow \sqrt{2} \approx 1.414 < 1.5$ 전역 이웃 $N_{\epsilon}(P_1) = N_{\epsilon}(P_2) = N_{\epsilon}(P_3) = N_{\epsilon}(P_4) = 4$
 $N_{\epsilon}(P_5) = N_{\epsilon}(P_6) = 3$, $N_{\epsilon}(P_7) = 2$, $N_{\epsilon}(P_8) = 4$, $N_{\epsilon}(P_9) = 1$

2) minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

$\text{Core} = \{P_1, P_2, P_3, P_4, P_5, P_6, P_8\}$, $\text{Border} = \{P_7\}$, $\text{Noise} = \{P_9\}$

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

$C_1 = \{P_1, P_2, P_3, P_4\}$, $C_2 = \{P_5, P_6, P_7, P_8\}$, $\text{Noise} = \{P_9\}$
 DBSCAN은 밀도 연결 영역을 하나의 군집으로 지정하기 때문.



Reference

- 26-2 Math for DS (15 기 김시원)
 - 26-2 ML-supervised learning (15 기 조유빈)
 - 26-2 ML-unsupervised learning (15 기 현승원)

Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원