

26-2 DSL 정규 세션

Part 1 과제



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시요. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

$$\det(A - \lambda I) = (4 - \lambda)(1 - \lambda) - 2 = \lambda(\lambda - 5) = 0$$

$$\lambda_1 = 0 \quad \lambda_2 = 5 \quad v_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad v_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P 는 직교행렬, D 는 고윳값 대각행렬)

$$P = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix} \quad D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

$$\lambda_1 = 0 \quad \lambda_2 = 5 > 0 \quad \rightarrow \text{PSD}$$

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

일반 정사각행렬은 고유벡터를 적절히 잡는다.
 직교는 대칭행렬에 해당하는 성질로 비대칭행렬에서는 보장받지 않는다.
 실수행렬은 스칼라형 행에 의해서 고윳값이 모두 실수이고 고유벡터를 항상
 정사각으로 잡을 수 있기, 직교행렬 P 로 $A = PDP^T$ 형태의 직교대각화가 언제나 가능하다.

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1) $B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

$$B^T B = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix} \quad BB^T = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

$$(9-\lambda)^2 - 49 = 0 \quad 9-\lambda = \pm 7 \quad \lambda = 16, 2 \quad \lambda=16 \quad (1,1) \quad v_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} \quad \lambda=2 \quad (1,-1) \quad v_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} \quad V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \quad \sigma_1 = 4 \quad \sigma_2 = \sqrt{2}$$

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3개 나오며, 그중 가장 작은 고윳값은 0이 됩니다.)

$$BB^T \quad \lambda = 16, 2, 0 \quad u_1 = Bv_1/4 = (4, 0, 4) / \sqrt{2} \cdot 4 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ \frac{1}{\sqrt{2}} \end{bmatrix} \quad u_2 = Bv_2/\sqrt{2} = (0, 2, 0) / \sqrt{2} \cdot \sqrt{2} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad u_3 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ -\frac{1}{\sqrt{2}} \end{bmatrix} \quad U = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U\Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0인 3×2 직사각 대각행렬입니다.)

$$B = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1) Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

$$\lambda_1 = 8 \quad \lambda_2 = 2$$

$$V_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} \quad V_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

$$PC1 = V_1 \quad PC2 = V_2$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

$$df = 2 = 10 \quad PC1 = \frac{8}{10}$$

$$PC2 = \frac{2}{10}$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

$$20\%$$

PCA에서 주성분이 설명하는 값은 고윳값과 같고
PC2의 고윳값이 2이므로 20%

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

$$P(A) = \frac{8}{16} \quad P(B) = \frac{4}{16} \quad P(C) = \frac{4}{16}$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

$$H(X) = -[0.5 \log_2 0.5 + 0.25 \log_2 0.25 + 0.25 \log_2 0.25] = 1.5$$

3) 엔트로피의 최대값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$\text{최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생하며, 최대 엔트로피는 } \log_2 3$$

2-2: KL-Divergence

두 확률 분포 P와 Q가 다음과 같이 주어졌습니다.

X	A	B	C
P(X)	0.5	0.3	0.2
Q(X)	0.25	0.5	0.25

1) $D_{KL}(P||Q)$ 와 $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence가

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

$$D_{KL}(P||Q) = 0.5 \log_2 (0.5/0.25) + 0.3 \log_2 (0.3/0.5) + 0.2 \log_2 (0.2/0.25) \\ = 0.2445 \quad D_{KL}(Q||P) = 0.199 \quad \neq$$

2) KL Divergence의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

$$\text{두 확률 분포가 같을 때 } P(X) = Q(X) \text{ 일때 } D_{KL}(P||Q) = 0$$

3. Regression

3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 (n=5).

x	1	2	3	4	5
y	2	3	5	6	9

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

$$\bar{x} = 3 \quad \bar{y} = 5 \quad S_{xy} = 17 \\ S_{xx} = 10$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

$$\hat{\beta}_1 = S_{xy} / S_{xx} = 1.7 \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = -0.1$$

$$\hat{y} = -0.1 + 1.7x$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

$$SSE = 1.1 \quad R^2 = 0.9633 \\ SST = 20$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

$$R^2 \approx 0.9633 \quad \text{설명력 매우 높음}$$

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해 X_1 의 VIF 를 계산하세요.

$$VIF = 1 / (1 - R^2) = 1 / 0.1 = 10$$

2) 위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

$$VIF \geq 5 \text{ 는 } \text{우려} \quad VIF \geq 10 \text{ 심각한 다중공선성.}$$

변수제거 필요

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3.5,4)
Class B (○): (5,5), (5,3), (6,4)

새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN 으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요

$$\begin{array}{ll} A1 = \sqrt{8} & B1 = \sqrt{2} \\ A2 = 0.5 & B2 = \sqrt{2} \\ & B3 = 2 \end{array}$$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

$$A2(0.5) \quad B1(\sqrt{2}) \quad B2(\sqrt{2}) \rightarrow \text{class B}$$

3) 거리의 역수 $w_i = \frac{1}{d(X_q, X_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

$$\begin{array}{lll} A2: 1/0.5 = 2 & B1: 1/\sqrt{2} = 0.707 & B2: 1/\sqrt{2} = 0.707 \\ A \text{ 가 } 2 & B \text{ 가 } \sqrt{2} & \rightarrow \text{class A} \end{array}$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

~~단순 다수결~~ : B
weighted KNN = A
K가 작을수록 이웃의 거리 분포

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)
초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

$$\{P1, P2, P3\} \quad \{P4, P5, P6\}$$

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

$$C1' = (2.33, 2)$$

$$C2' = (8.33, 8.33)$$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

$$\text{중심} \rightarrow \text{평균} \rightarrow \text{중심}$$

5-2: DBSCAN

다음과 같은 2 차원 데이터에 $\text{eps} = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

$P1(1,1)$, $P2(1,2)$, $P3(2,1)$, $P4(2,2)$, $P5(8,8)$, $P6(8,9)$, $P7(10,8)$, $P8(9,8)$, $P9(12,12)$

1) 각 점에 대해 eps 반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가 eps 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

$\text{min } d \leq 1.5$
 $P1 \rightarrow P1, P2, P3, P4$ $P4 \rightarrow P1, P2, P3, P4$ $P7 \rightarrow P7, P8$
 $P2 \rightarrow P1, P2, P3, P4$ $P5 \rightarrow P5, P6, P8$ $P8 \rightarrow P5, P6, P7, P8$
 $P3 \rightarrow P1, P2, P3, P4$ $P6 \rightarrow P5, P6, P8$ $P9 \rightarrow P9$

2) minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

$\text{minPts} = 3$
 core point = $P1, P2, P3, P4, P5, P6, P8$
 border point = $P7$
 noise point = $P9$

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

$C1 : \{P1, P2, P3, P4\}$
 $C2 : \{P5, P6, P8, P7\}$
 noise : $P9$

Reference

- 26-2 Math for DS (15 기 김시원)
 - 26-2 ML-supervised learning (15 기 조유빈)
 - 26-2 ML-unsupervised learning (15 기 현승원)

Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원