

26-2 DSL 정규 세션

Part 1 과제



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시요. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

$$A - \lambda I = \begin{vmatrix} 4-\lambda & 2 \\ 2 & 1-\lambda \end{vmatrix} = (4-\lambda)(1-\lambda) - 4 = 0$$

$$\lambda^2 - 5\lambda = \lambda(\lambda - 5) = 0$$

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$\lambda = 0: \begin{vmatrix} 4 & 2 \\ 2 & 1 \end{vmatrix} = \begin{vmatrix} 2 & 1 \\ 0 & 0 \end{vmatrix}$$

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

span (1, -2)

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

$$\lambda = 5: \begin{vmatrix} -1 & 2 \\ 2 & -4 \end{vmatrix} = \begin{vmatrix} 1 & -2 \\ 0 & 0 \end{vmatrix}$$

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

$$v_1 = \begin{pmatrix} 1/\sqrt{5} \\ -2/\sqrt{5} \end{pmatrix} \quad v_2 = \begin{pmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \end{pmatrix}$$

span (2, 1)

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P는 직교행렬, D는 고윳값 대각행렬)

$$A = \begin{pmatrix} 1/\sqrt{5} & 2/\sqrt{5} \\ -2/\sqrt{5} & 1/\sqrt{5} \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & 5 \end{pmatrix} \begin{pmatrix} 1/\sqrt{5} & -2/\sqrt{5} \\ 2/\sqrt{5} & 1/\sqrt{5} \end{pmatrix}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

PSD. ($\lambda \geq 0$)

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

1-2: 특잇값 분해

$$B^T B = \begin{pmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{pmatrix} \begin{pmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{pmatrix} = \begin{pmatrix} 9 & 7 \\ 7 & 9 \end{pmatrix}$$

다음과 같은 행렬 B 가 주어져 있습니다.

$$\frac{61}{49} \\ \frac{92}{92}$$

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

$$B B^T = \begin{pmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{pmatrix} = \begin{pmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{pmatrix}$$

1) $B^T B$ (2×2)와 $B B^T$ (3×3)를 각각 계산하세요.

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

$$\sigma_1 = 4 \quad \sigma_2 = \sqrt{2}, \quad V = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{pmatrix}$$

3) $B B^T$ 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. ($B B^T$ 는 3×3 이므로 고윳값이 3 개 나오며, 그중 가장 작은 고윳값은 0 이 됩니다.)

$$\lambda = 16, 2, 0$$

$$U = \begin{pmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{pmatrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U \Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0 인 3×2 직사각 대각행렬입니다.)

$$B = \begin{pmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{pmatrix}$$

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

$$\begin{array}{cc} \lambda-5 & 3 \\ 3 & \lambda-5 \end{array} : \lambda^2 - 10\lambda + 16 = (\lambda-2)(\lambda-8)$$

$$\lambda=2 \quad \begin{vmatrix} -3 & 3 \\ 3 & -3 \end{vmatrix} = \begin{vmatrix} 1 & -1 \\ 0 & 0 \end{vmatrix}$$

1) Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요. $\lambda=8 \quad \begin{vmatrix} 3 & 3 \\ 3 & 3 \end{vmatrix} = \begin{vmatrix} 1 & 1 \\ 0 & 0 \end{vmatrix}$

$$\lambda=2 \quad v_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} \quad \lambda=8 \quad v_2 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA 에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

$$PC1: \lambda=8. \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix} \quad PC2: \lambda=2 \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

$$PC1: 0.8 \quad PC2: 0.2$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

20%. PC1에서 80%만 설명하기 때문에

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

$$P(A) = \frac{1}{2} \quad P(B) = \frac{1}{4} \quad P(C) = \frac{1}{4}$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

$$H(X) = -\frac{1}{2} \cdot (-1) - \frac{1}{4} \cdot (-2) - \frac{1}{4} \cdot (-2) = \frac{1}{2} + \frac{1}{2} + \frac{1}{2} = \frac{3}{2}$$

3) 엔트로피의 최대값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$H_{\max} = -3 \cdot \frac{1}{3} \log_2 \frac{1}{3} = 1.585$$

현재 엔트로피 1.5는 최대값과 가까움, 고르게 분포하여 데이터의 불확실성 높은 상태

2-2: KL-Divergence

두 확률 분포 P 와 Q 가 다음과 같이 주어졌습니다.

X	A	B	C
P(X)	0.5	0.3	0.2
Q(X)	0.25	0.5	0.25

1) $D_{KL}(P||Q)$ 와 $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence 가

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

$$D_{KL}(P||Q) = 0.215 \quad D_{KL}(Q||P) = 0.198$$

거리의 정의를 만족하려면 대칭 상황에서도 성립해야 하는데, KL-divergence는 성립하지 않아서

2) KL Divergence 의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

독립성분포 P와 Q가 얼마나 다른지 나타내는 지표

$$P와 Q가 완전히 동일할 때 \quad D_{KL}(P||Q) = 0$$

3. Regression

3-1: 단순 선형 회귀

$$\begin{aligned} &6 + 2 + 1 + 8 \\ &4 + 1 + 1 + 4 \end{aligned}$$

다음과 같은 데이터가 주어져 있습니다 (n=5).

x	1	2	3	4	5
y	2	3	5	6	9

$$\begin{aligned} \bar{x} &= 3 \\ \bar{y} &= 5 \end{aligned}$$

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

$$S_{xy} = 12 \quad S_{xx} = 10$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

$$\begin{aligned} &= \frac{12}{10} = 1.2 \\ &= 5 - 1.2 \cdot 3 = -0.6 \end{aligned} \quad \hat{y} = -0.6 + 1.2x$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

$$e_i: 0.4 \quad -0.2 \quad 0 \quad -0.2 \quad 0.6 \quad R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.1}{1.1} = 0.9677$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

결정계수 R^2 은 0과 1 사이 생성, 1에 가까우므로 잘 설명함

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해 X_1 의 VIF 를 계산하세요.

$$VIF: \frac{1}{1-R^2} = 10$$

2) 위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

VIF 값이 10보다 크면 다중공선성이 심함


이때 회귀계수 추정치의 분산이 커지면 모델의 신뢰성을 떨어뜨리므로
 X_1 변수를 제거하는 것이 낫다

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3.5,4)
Class B (○): (5,5), (5,3), (6,4)



새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN 으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요

$$d(q, A_1) = \sqrt{16} \quad d(q, B_1) = \sqrt{2} \quad d(q, B_2) = 2$$

$$d(q, A_2) = \sqrt{\frac{1}{4}} = \frac{1}{2} \quad d(q, B_3) = \sqrt{2}$$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

$(3.5, 4)$ $(4, 4)$ $(6, 3)$ 클래스 B.
A B

3) 거리의 역수 $w_i = \frac{1}{d(X_q, X_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

$$w_{A_2} = 2 \quad \rightarrow 2 \quad \therefore q \text{ 는 클래스 A}$$

$$w_{B_1} = w_{B_3} = \frac{1}{\sqrt{2}} \quad \rightarrow \frac{2}{2} = 1.414$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

다르다. 단순 다수결은 개수만을 중요하게 여긴 반면,

거리분포는 A가 더 가까워서 큰 가중치가 부과된다.

멀리 떨어진 B 2개의 가중치보다 A의 영향력이 더 컸다.

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)



P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)

초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

C1: P1, P2, P3 C2: P4, P5, P6

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

C1 평균: $(\frac{7}{3}, 2)$ C2 평균: $(\frac{25}{3}, \frac{25}{3})$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

동일하게 유지되었으므로 수렴함

5-2: DBSCAN

다음과 같은 2 차원 데이터에 $\text{eps} = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

$P_1(1,1)$, $P_2(1,2)$, $P_3(2,1)$, $P_4(2,2)$, $P_5(8,8)$, $P_6(8,9)$, $P_7(10,8)$, $P_8(9,8)$, $P_9(12,12)$

1) 각 점에 대해 eps 반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가 eps 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

$P_1: 4$ $P_2: 4$ $P_3: 4$ $P_4: 4$ $P_5: 1$ $P_6: 1$ $P_7: 2$ $P_8: 4$ $P_9: 1$

2) minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

Core point : $P_1, P_2, P_3, P_4, P_7, P_8$ Noise : P_9

border point : P_5

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

군집 1: P_1, P_2, P_3, P_4

군집 2: P_5, P_6, P_7, P_8

군집 3: P_9

각 점에서 거리를 구하고

인접한 것끼리 묶기 때문에

개수를 지정할 필요가 없다

Reference

- 26-2 Math for DS (15 기 김시원)
- 26-2 ML-supervised learning (15 기 조유빈)
- 26-2 ML-unsupervised learning (15 기 현승원)

Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원