

26-2 DSL 정규 세션 Part 1 과제

기수: 15기 이름: 박현진 (Hyunjin PARK)

1. Linear Algebra

1-1: 고윳값 분해

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) 고윳값과 단위 고유벡터

특성방정식은

$$\det(A - \lambda I) = \begin{vmatrix} 4 - \lambda & 2 \\ 2 & 1 - \lambda \end{vmatrix} = (4 - \lambda)(1 - \lambda) - 4 = \lambda^2 - 5\lambda = \lambda(\lambda - 5)$$

이므로 고윳값은 $\lambda_1 = 5$, $\lambda_2 = 0$ 이다.

$\lambda = 5$ 일 때 $(A - 5I)\mathbf{x} = \begin{bmatrix} -1 & 2 \\ 2 & -4 \end{bmatrix}\mathbf{x} = \mathbf{0}$ 에서 $x_1 = 2x_2$ 이므로 고유벡터는 $(2, 1)^T$ 의 상수배이고, 정규화하면

$$\mathbf{v}_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$\lambda = 0$ 일 때는 $A\mathbf{x} = \mathbf{0}$ 에서 $2x_1 + x_2 = 0$, 즉 $x_2 = -2x_1$ 이므로

$$\mathbf{v}_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

$\mathbf{v}_1^T \mathbf{v}_2 = \frac{1}{5}(2 - 2) = 0$ 이라 두 고유벡터는 서로 직교한다.

2) 직교대각화 $A = PDP^T$

단위 고유벡터를 열로 놓으면

$$P = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix}, \quad D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}$$

P 의 두 열이 정규직교이므로 $P^T P = I$, 즉 P 는 직교행렬이다. 곱을 직접 계산해 보면

$$PDP^T = \frac{1}{5} \begin{bmatrix} 10 & 0 \\ 5 & 0 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix} = \frac{1}{5} \begin{bmatrix} 20 & 10 \\ 10 & 5 \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

으로 원래 A 가 나온다.

3) 정부호성 판별

고윳값이 5와 0이므로 전부 0 이상이지만 하나가 0이다. 임의의 $\mathbf{x}$ 에 대해

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = 5(\mathbf{v}_1^T \mathbf{x})^2 + 0 \cdot (\mathbf{v}_2^T \mathbf{x})^2 \geq 0$$

이고, $\mathbf{x} = \mathbf{v}_2 \neq \mathbf{0}$ 을 넣으면 값이 정확히 0이 된다. 따라서 $\mathbf{A}$ 는 PSD(양의 준정부호)이다. $\det \mathbf{A} = 0$ 이라 PD는 될 수 없다.

4) (Optional) 일반 정사각행렬에서 고유벡터가 직교하지 않는 이유

두 고윳값 $\lambda_1 \neq \lambda_2$ 에 대해

$$\lambda_1 \mathbf{v}_2^T \mathbf{v}_1 = \mathbf{v}_2^T \mathbf{A} \mathbf{v}_1 = (\mathbf{A}^T \mathbf{v}_2)^T \mathbf{v}_1$$

이 성립한다. 여기서 $\mathbf{A}^T \mathbf{v}_2 = \lambda_2 \mathbf{v}_2$ 여야 우변이 $\lambda_2 \mathbf{v}_2^T \mathbf{v}_1$ 이 되고, 그래야 $(\lambda_1 - \lambda_2) \mathbf{v}_2^T \mathbf{v}_1 = 0$ 에서 직교라는 결론이 나온다. 그런데 $\mathbf{A}^T \neq \mathbf{A}$ 이면 $\mathbf{A}$ 의 고유벡터가 $\mathbf{A}^T$ 의 고유벡터라는 보장이 없어 이 단계가 막힌다. 서로 다른 고윳값의 고유벡터는 일차독립이기는 하지만 직교할 이유가 없고, 대각화가 되더라도 $\mathbf{P}$ 가 직교행렬이 아닌 $\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^{-1}$ 꼴에 그친다. 실제로 $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 의 고유벡터는 $(1, 0)^T$, $(1, 1)^T$ 로 내적이 1이다. 더 나아가 $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 처럼 고유벡터가 모자라 대각화 자체가 안 되는 경우도 있다.

실수 대칭행렬에서 항상 직교대각화가 되는 것은 스펙트럼 정리 때문이다. 우선 $\bar{\mathbf{v}}^T \mathbf{A} \mathbf{v} = \lambda \|\mathbf{v}\|^2$ 의 좌변이 에르미트 형식이라 실수이므로 고윳값이 항상 실수이고, 고유벡터도 실벡터로 잡을 수 있다. 그리고 $\mathbf{A}^T = \mathbf{A}$ 이면 위 식이 그대로 $\lambda_1 \mathbf{v}_2^T \mathbf{v}_1 = \lambda_2 \mathbf{v}_2^T \mathbf{v}_1$ 이 되어 서로 다른 고윳값의 고유벡터가 직교한다. 마지막으로 대칭행렬은 고윳값이 중복돼도 기하적 중복도와 대수적 중복도가 같아 고유벡터가 모자라는 일이 없으므로, 각 고유공간에서 Gram-Schmidt로 정규직교기저를 잡으면 $\mathbb{R}^n$ 전체의 정규직교 고유기저가 만들어진다. 이것을 모은 $\mathbf{P}$ 는 $\mathbf{P}^{-1} = \mathbf{P}^T$ 를 만족한다.

1-2: 특잇값 분해

$$\mathbf{B} = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1) $\mathbf{B}^T \mathbf{B}$ 와 $\mathbf{B} \mathbf{B}^T$

$$\mathbf{B}^T \mathbf{B} = \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 4+1+4 & 4-1+4 \\ 4-1+4 & 4+1+4 \end{bmatrix} = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix}$$

$$\mathbf{B} \mathbf{B}^T = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2) $B^T B$ 의 고윳값·고유벡터와 특잇값

$$\det(B^T B - \lambda I) = (9 - \lambda)^2 - 49 = \lambda^2 - 18\lambda + 32 = (\lambda - 16)(\lambda - 2)$$

이므로 $\lambda_1 = 16, \lambda_2 = 2$ 이다.

$\lambda = 16$ 에서는 $\begin{bmatrix} -7 & 7 \\ 7 & -7 \end{bmatrix} \mathbf{x} = \mathbf{0}$ 이라 $x_1 = x_2$, $\lambda = 2$ 에서는 $\begin{bmatrix} 7 & 7 \\ 7 & 7 \end{bmatrix} \mathbf{x} = \mathbf{0}$ 이라 $x_1 = -x_2$ 이므로

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \sigma_1 = \sqrt{16} = 4, \quad \sigma_2 = \sqrt{2} \approx 1.4142$$

3) BB^T 의 고윳값·고유벡터와 U

$$\det(BB^T - \lambda I) = \begin{vmatrix} 8 - \lambda & 0 & 8 \\ 0 & 2 - \lambda & 0 \\ 8 & 0 & 8 - \lambda \end{vmatrix} = (2 - \lambda)[(8 - \lambda)^2 - 64] = (2 - \lambda)\lambda(\lambda - 16)$$

이므로 고윳값은 16, 2, 0이다. 0이 아닌 두 개가 $B^T B$ 의 고윳값과 일치하고 거기에 0이 하나 붙는 형태다.

- $\lambda = 16$: $-8u_1 + 8u_3 = 0, -14u_2 = 0$ 에서 $u_1 = u_3, u_2 = 0 \rightarrow \mathbf{u}_1 = \frac{1}{\sqrt{2}}(1, 0, 1)^T$
- $\lambda = 2$: $6u_1 + 8u_3 = 0, 8u_1 + 6u_3 = 0$ 에서 $u_1 = u_3 = 0 \rightarrow \mathbf{u}_2 = (0, 1, 0)^T$
- $\lambda = 0$: $8u_1 + 8u_3 = 0, 2u_2 = 0$ 에서 $u_3 = -u_1, u_2 = 0 \rightarrow \mathbf{u}_3 = \frac{1}{\sqrt{2}}(1, 0, -1)^T$

고유벡터는 부호를 뒤집어도 되므로 $\mathbf{u}_i = B\mathbf{v}_i/\sigma_i$ 와 맞는 쪽으로 잡아야 한다. 확인해 보면

$$\frac{B\mathbf{v}_1}{\sigma_1} = \frac{1}{4} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 4 \\ 0 \\ 4 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \frac{B\mathbf{v}_2}{\sigma_2} = \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

로 위에서 잡은 부호와 일치한다.

$$U = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

4) $B = U\Sigma V^T$

$$\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

$$B = U\Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

실제로 곱해 보면

$$U\Sigma = \begin{bmatrix} 2\sqrt{2} & 0 \\ 0 & \sqrt{2} \\ 2\sqrt{2} & 0 \end{bmatrix}, \quad (U\Sigma)V^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 2\sqrt{2} & 2\sqrt{2} \\ \sqrt{2} & -\sqrt{2} \\ 2\sqrt{2} & 2\sqrt{2} \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

로 B 가 복원된다. $\sigma_3 = 0$ 인 이유는 $\text{rank}(B) = 2$ 이기 때문이고, 이때 $\mathbf{u}_3$ 는 B 의 열공간에 직교하는 방향이다.

1-3: 주성분 분석 (PCA)

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1) 고윳값과 단위 고유벡터

$$\det(\Sigma - \lambda I) = (5 - \lambda)^2 - 9 = \lambda^2 - 10\lambda + 16 = (\lambda - 8)(\lambda - 2)$$

이므로 $\lambda_1 = 8, \lambda_2 = 2$ 이다. 각각에 대해 $\mathbf{x}_1 = \mathbf{x}_2, \mathbf{x}_1 = -\mathbf{x}_2$ 가 나오므로

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}}(1, 1)^T, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}}(1, -1)^T$$

2) PC1, PC2 방향벡터

가장 큰 고윳값 8에 대응하는 것이 PC1이므로

$$\text{PC1} = \frac{1}{\sqrt{2}}(1, 1)^T \approx (0.7071, 0.7071)^T, \quad \text{PC2} = \frac{1}{\sqrt{2}}(1, -1)^T \approx (0.7071, -0.7071)^T$$

PC1은 $+45^\circ$ 방향, PC2는 그에 직교하는 -45° 방향이다. 공분산이 $+3$ 으로 양수라 두 변수가 같이 커지는 방향으로 데이터가 가장 넓게 퍼져 있을 텐데, 그 결과와 잘 맞는다.

3) 설명분산 비율

전체 분산은 $\text{tr}(\Sigma) = 10$ 이고 이는 $\lambda_1 + \lambda_2 = 8 + 2$ 와 같다.

$$\text{EVR}_1 = \frac{8}{10} = 0.8, \quad \text{EVR}_2 = \frac{2}{10} = 0.2$$

4) 1차원 축소 시 설명되지 않는 분산

설명되지 않는 비율은 $1 - 0.8 = 0.2$, 즉 20%이다.

PCA는 공분산행렬을 직교대각화해서 얻은 정규직교 기저로 좌표축을 회전시킨 것이므로, 회전 후 각 축의 분산이 정확히 $\lambda_1 = 8, \lambda_2 = 2$ 가 되고 축 사이의 공분산은 0이 된다. 총분산이 축별로 깔끔하게 쪼개지기 때문에 PC2를 버릴 때 잃는 양도 정확히 $\lambda_2 = 2$ 이다. 재구성 오차로 써 보면

$$\mathbb{E} \|\mathbf{x} - (\mathbf{v}_1^T \mathbf{x}) \mathbf{v}_1\|^2 = \lambda_2 = 2$$

이고 전체 10에 대해 20%이다.

2. Information Theory

2-1: Entropy

전체 16개, 클래스별로 A 8개, B 4개, C 4개.

1) 발생확률

$$P(A) = \frac{8}{16} = 0.5, \quad P(B) = P(C) = \frac{4}{16} = 0.25$$

2) 엔트로피

$$\begin{aligned} H(X) &= -\left[\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{4}\log_2 \frac{1}{4} + \frac{1}{4}\log_2 \frac{1}{4}\right] \\ &= -\left[\frac{1}{2}(-1) + \frac{1}{4}(-2) + \frac{1}{4}(-2)\right] \\ &= 0.5 + 0.5 + 0.5 = 1.5 \text{ bits} \end{aligned}$$

3) 최대 엔트로피와의 비교

클래스가 3개일 때 엔트로피는 세 확률이 모두 $1/3$ 일 때 최대이고, 그 값은 $\log_2 3 \approx 1.585$ bits 이다. 반대로 한 클래스에 확률이 전부 몰리면 0이 된다.

현재 값 1.5는 최댓값의 약 95% 수준이다. A가 절반을 차지해 완전한 균등분포는 아니지만, 그 편중으로 줄어든 불확실성이 $1.585 - 1.5 = 0.085$ bit 에 그치므로 사실상 최대 불확실성에 가까운 상태로 볼 수 있다.

2-2: KL-Divergence

X	A	B	C
$P(X)$	0.5	0.3	0.2
$Q(X)$	0.25	0.5	0.25

1) $D_{KL}(P\|Q)$ 와 $D_{KL}(Q\|P)$

$$\begin{aligned} D_{KL}(P\|Q) &= 0.5 \log_2 \frac{0.5}{0.25} + 0.3 \log_2 \frac{0.3}{0.5} + 0.2 \log_2 \frac{0.2}{0.25} \\ &= 0.5(1) + 0.3(-0.73697) + 0.2(-0.32193) \\ &= 0.5 - 0.22109 - 0.06439 = 0.2145 \text{ bits} \end{aligned}$$

$$\begin{aligned}
 D_{KL}(Q\|P) &= 0.25 \log_2 \frac{0.25}{0.5} + 0.5 \log_2 \frac{0.5}{0.3} + 0.25 \log_2 \frac{0.25}{0.2} \\
 &= 0.25(-1) + 0.5(0.73697) + 0.25(0.32193) \\
 &= -0.25 + 0.36848 + 0.08048 = 0.1990 \text{ bits}
 \end{aligned}$$

두 값이 $0.2145 \neq 0.1990$ 으로 다르다.

거리(metric)라고 하려면 비음수성, $d(p, q) = 0 \iff p = q$ 대칭성, 삼각부등식을 모두 만족해야 한다. KL-divergence는 앞의 두 조건은 만족하지만 위 계산에서 보듯 대칭성이 깨지고, 삼각부등식도 일반적으로 성립하지 않는다. 정의식 $\sum P \log(P/Q)$ 에서 기댓값을 취하는 기준이 앞쪽 분포 P 로 고정돼 있어 두 분포의 역할이 처음부터 대등하지 않기 때문이다. $D_{KL}(P\|Q)$ 는 P 가 확률을 크게 주는 사건에서 Q 가 얼마나 어긋나는지에 가중치를 두고, 반대 방향은 그 반대다. 그래서 거리가 아니라 divergence라고 부른다.

비대칭성이 극단적으로 드러나는 경우로, 어떤 x 에서 $Q(x) = 0$ 이고 $P(x) > 0$ 이면 $D_{KL}(P\|Q) = \infty$ 인데 $D_{KL}(Q\|P)$ 는 유한할 수 있다.

2) KL Divergence 의 의미와 0이 되는 조건

식을 풀어 쓰면

$$D_{KL}(P\|Q) = \underbrace{\left(- \sum_x P(x) \log_2 Q(x) \right)}_{H(P,Q)} - \underbrace{\left(- \sum_x P(x) \log_2 P(x) \right)}_{H(P)}$$

이므로, 실제 분포가 P 인데 Q 가 맞다고 생각하고 부호를 설계했을 때 추가로 더 쓰게 되는 평균 비트 수로 읽을 수 있다. 이 문제에서 $H(P) = 1.4855$, $H(P, Q) = 1.7$ 이라 차이가 0.2145 bit 로 앞의 계산과 맞는다. 통계적으로는 관측이 P 에서 나왔을 때 Q 대신 P 를 지지하는 로그우도비의 기댓값이기도 하다. 분류 문제에서 cross-entropy loss를 최소화하는 것이 사실상 KL divergence 최소화와 같은 이유도 여기에 있다. $H(P)$ 는 데이터로 정해진 상수라 최소화 대상에서 빠지기 때문이다.

$D_{KL}(P\|Q) = 0$ 이 되는 것은 두 분포가 완전히 같을 때뿐이다. $\ln t \leq t - 1$ 이고 등호가 $t = 1$ 에서만 성립하는 것을 쓰면

$$-D_{KL}(P\|Q) = \sum_x P(x) \ln \frac{Q(x)}{P(x)} \leq \sum_x P(x) \left(\frac{Q(x)}{P(x)} - 1 \right) = \sum_x Q(x) - \sum_x P(x) = 0$$

이라 항상 $D_{KL} \geq 0$ 이고, 등호는 $P(x) > 0$ 인 모든 x 에서 $Q(x)/P(x) = 1$ 일 때, 즉 $P \equiv Q$ 일 때만 성립한다. 이 문제의 P 와 Q 는 다르므로 양쪽 다 0보다 크게 나왔다.

3. Regression

3-1: 단순 선형 회귀

x_i	1	2	3	4	5
y_i	2	3	5	6	9

1) $\bar{x}$, $\bar{y}$, S_{xy} , S_{xx}

$$\bar{x} = \frac{15}{5} = 3, \quad \bar{y} = \frac{25}{5} = 5$$

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	2	-2	-3	6	4
2	3	-1	-2	2	1
3	5	0	0	0	0
4	6	1	1	1	1
5	9	2	4	8	4
			합계	17	10

따라서 $S_{xy} = 17$, $S_{xx} = 10$ 이다.

2) 회귀직선

$$\hat{\beta}_1 = \frac{17}{10} = 1.7, \quad \hat{\beta}_0 = 5 - 1.7 \times 3 = -0.1$$

$$\hat{y} = -0.1 + 1.7x$$

x 가 1 늘어날 때 y 가 평균 1.7 늘어난다는 뜻이다.

3) 잔차, SSE, SST, R^2

x_i	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$	e_i^2	$(y_i - \bar{y})^2$
1	2	1.6	0.4	0.16	9
2	3	3.3	-0.3	0.09	4
3	5	5.0	0.0	0.00	0
4	6	6.7	-0.7	0.49	1
5	9	8.4	0.6	0.36	16
		합계	0	1.10	30

잔차의 합이 0으로 나오는 것은 최소제곱 정규방정식에서 따라오는 결과라 계산에 쓸 수 있다.

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.10}{30} = 0.9633$$

참고로 $SSR = 30 - 1.10 = 28.9$ 인데, 이는 $\hat{\beta}_1 S_{xy} = 1.7 \times 17 = 28.9$ 와 같다.

4) R^2 에 대한 평가

$R^2 = 0.9633$ 이므로 y 의 총변동 30 중 96.3%를 회귀직선이 설명하고 1.1만 남는다. 잔차도 가장 큰 것이 0.7로 y 의 범위(2~9)에 비해 작다. 이 직선은 데이터를 잘 설명한다고 볼 수 있다.

3-2: 다중공선성 & VIF

1) VIF 계산

X_1 을 X_2, X_3 로 회귀했을 때 $R_1^2 = 0.9$ 이므로

$$VIF_1 = \frac{1}{1 - R_1^2} = \frac{1}{0.1} = 10$$

2) 다중공선성 수준 평가와 변수 제거 여부

VIF	해석
≈ 1	다중공선성 없음
$1 \sim 5$	경미, 대체로 허용
$5 \sim 10$	주의
≥ 10	심각

$VIF_1 = 10$ 은 흔히 쓰는 임계값에 정확히 걸리므로 X_1 의 다중공선성은 심각한 수준이다. X_1 의 변동 중 90%가 이미 X_2, X_3 로 설명되고 X_1 만의 고유한 정보는 10%밖에 안 된다는 뜻이다.

이게 문제가 되는 이유는 계수의 분산이

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{11}} \cdot VIF_1$$

이라 공선성이 없을 때보다 분산이 10배, 표준오차가 $\sqrt{10} \approx 3.16$ 배로 부풀기 때문이다. 그러면 t 통계량이 1/3 수준으로 줄어 계수가 유의하지 않게 나오기 쉽고, 표본이 조금만 바뀌어도 추정값이 크게 흔들리거나 부호가 이론과 반대로 나오기도 한다. 모형 전체는 F 검정에서 유의한데 개별 계수는 전부 유의하지 않은 상황이 대표적이다.

변수를 빼야 하는지는 분석 목적에 따라 다르다. 예측이 목적이라면 굳이 뺄 필요가 없다. 다중공선성은 계수 추정을 불안정하게 만들 뿐 $\hat{y}$ 의 예측 성능 자체는 크게 해치지 않기 때문이다. 반면 각 변수가 y 에 얼마나 기여하는지 해석하는 것이 목적이라면 조치가 필요하다. 먼저 X_1 이 X_2, X_3 의 선형결합에 가까운 것인지, 단위나 스케일이 겹쳐서 생긴 구조적 중복인지 확인하고, 구조적 중복이면 그 항을 없앤다. 그게 아니라면 도메인 지식으로 셋 중 이론적으로 중요한 변수를 남기거나 중복되는 것들을 하나로 합치고, 세 변수를 다 써야 한다면 Ridge 회귀처럼 계수 분산을 줄여 주는 방법을 쓰는 편이 낫다.

기계적으로 X_1 을 빼는 것은 조심해야 한다. X_1 이 실제로 y 를 설명하는 변수였다면 제거하는 순간 누락변수 편향이 생겨 나머지 계수까지 왜곡된다. 분산은 줄지만 편향이 늘어나는 트레이드오프이므로 제거 전후의 성능을 비교해서 결정하는 것이 안전하다.

4. Classification

4-1: KNN

Class A (●) (1,1), (3.5,4) / Class B (○) (5,5), (5,3), (6,4), 질의점 $q = (4,4)$, $K = 3$.

1) 유클리드 거리

점	좌표	클래스	계산	$d(q, x_i)$
x_1	(1,1)	A	$\sqrt{3^2 + 3^2} = \sqrt{18}$	4.2426
x_2	(3.5,4)	A	$\sqrt{0.5^2 + 0^2}$	0.5000
x_3	(5,5)	B	$\sqrt{1^2 + 1^2} = \sqrt{2}$	1.4142
x_4	(5,3)	B	$\sqrt{1^2 + 1^2} = \sqrt{2}$	1.4142
x_5	(6,4)	B	$\sqrt{2^2 + 0^2}$	2.0000

2) $K = 3$ 단순 다수결

거리 순으로 정렬하면 $x_2(0.5) < x_3 = x_4(1.4142) < x_5(2) < x_1(4.2426)$ 이므로 가장 가까운 3개는 $x_2(A), x_3(B), x_4(B)$ 이다. A가 1표, B가 2표이므로 q 는 Class B로 분류된다.

3) Weighted KNN ($w_i = 1/d$)

같은 3개 이웃에 대해 가중치를 구하면 x_2 는 $1/0.5 = 2$, x_3 과 x_4 는 각각 $1/\sqrt{2} = 0.7071$ 이다. 클래스별로 더하면

$$W_A = 2.0000, \quad W_B = 0.7071 + 0.7071 = 1.4142$$

$W_A > W_B$ 이므로 이번에는 Class A로 분류된다.

4) 두 결과의 비교

단순 다수결은 B, weighted KNN은 A로 결과가 갈렸다.

단순 다수결은 이웃 3개를 전부 똑같은 1표로 세기 때문에, 거의 붙어 있는 $x_2(d = 0.5)$ 와 그보다 세 배 가까이 먼 $x_3, x_4(d = 1.414)$ 가 같은 영향력을 갖는다. 그래서 개수가 많은 B가 이긴다. 반면 $w = 1/d$ 를 쓰면 x_2 가 나머지보다 약 2.83배 가까운 만큼 표도 그만큼 커져서, A의 한 표(2.0)가 B의 두 표 합(1.414)을 넘어선다. 결국 가장 가까운 이웃과 그다음 이웃 사이의 거리 격차가 클 때 두 방법의 결론이 갈리는 셈인데, 이 문제가 정확히 그런 경우다. 세 이웃의 거리가 비슷했다면 가중치도 고만고만해져서 두 결과가 같았을 것이다.

K 값 관점에서 보면, $K = 1$ 이면 둘 다 x_2 만 보므로 A로 일치한다. $K = 3$ 에서 갈라졌고, $K = 5$ 로 전체를 다 쓰면 단순다수결은 A 2표 대 B 3표로 여전히 B, weighted는 $W_A = 2 + 1/4.2426 = 2.236$, $W_B = 0.7071 + 0.7071 + 0.5 = 1.914$ 로 여전히 A다. K 를 키우면 먼 이웃까지 표를 행사하게 되어 데이터가 많은 클래스(여기서는 5개 중 3개인 B) 쪽으로 끌려가기 쉬운데, 거리 가중을 주면 먼 이웃의 표가 자동으로 작아지므로 K 선택에 덜 민감해진다.

5. Clustering

5-1: K-means 클러스터링

$P_1(2, 3), P_2(2, 1), P_3(3, 2), P_4(8, 8), P_5(9, 8), P_6(8, 9), K = 2$, 초기 centroid $C_1 = (2, 3), C_2 = (8, 8)$.

1) 배정

점	좌표	$d(\cdot, C_1)$	$d(\cdot, C_2)$	배정
P_1	(2,3)	0	$\sqrt{61} \approx 7.810$	C_1
P_2	(2,1)	2	$\sqrt{85} \approx 9.220$	C_1
P_3	(3,2)	$\sqrt{2} \approx 1.414$	$\sqrt{61} \approx 7.810$	C_1
P_4	(8,8)	$\sqrt{61} \approx 7.810$	0	C_2
P_5	(9,8)	$\sqrt{74} \approx 8.602$	1	C_2
P_6	(8,9)	$\sqrt{72} \approx 8.485$	1	C_2

군집 1은 $\{P_1, P_2, P_3\}$, 군집 2는 $\{P_4, P_5, P_6\}$ 이다.

2) Centroid 갱신

$$C'_1 = \left(\frac{2+2+3}{3}, \frac{3+1+2}{3} \right) = \left(\frac{7}{3}, 2 \right) \approx (2.333, 2.000)$$

$$C'_2 = \left(\frac{8+9+8}{3}, \frac{8+8+9}{3} \right) = \left(\frac{25}{3}, \frac{25}{3} \right) \approx (8.333, 8.333)$$

3) 재배정과 수렴 판정

점	좌표	$d(\cdot, C'_1)$	$d(\cdot, C'_2)$	배정
P_1	(2,3)	1.054	8.279	C_1
P_2	(2,1)	1.054	9.690	C_1
P_3	(3,2)	0.667	8.279	C_1
P_4	(8,8)	8.253	0.471	C_2
P_5	(9,8)	8.969	0.745	C_2
P_6	(8,9)	9.006	0.745	C_2

배정 결과가 1회차와 똑같다. 배정이 그대로면 다음에 계산할 centroid도 같은 값이 나오므로 더 이상 변하지 않는다. 즉 알고리즘은 2회차에서 수렴했다.

5-2: DBSCAN

$P_1(1, 1), P_2(1, 2), P_3(2, 1), P_4(2, 2), P_5(8, 8), P_6(8, 9), P_7(10, 8), P_8(9, 8), P_9(12, 12), \epsilon = 1.5, \text{minPts} = 3.$

1) ε -이웃의 개수

$P_1 \sim P_4$ 는 한 변이 1인 정사각형을 이루므로 가장 먼 대각선끼리도 $\sqrt{2} \approx 1.414 \leq 1.5$ 라 넷이 서로 전부 이웃이다.

우상단 쪽은 $d(P_5, P_6) = 1$, $d(P_5, P_8) = 1$, $d(P_6, P_8) = \sqrt{2} \approx 1.414$, $d(P_7, P_8) = 1$ 로 여기까지는 이웃이지만, $d(P_5, P_7) = 2$ 와 $d(P_6, P_7) = \sqrt{5} \approx 2.236$ 은 ε 을 넘는다. P_9 는 가장 가까운 P_7 과도 $\sqrt{20} \approx 4.472$ 만큼 떨어져 있다.

점	좌표	ε -이웃 (자기 포함)	개수
P_1	(1,1)	P_1, P_2, P_3, P_4	4
P_2	(1,2)	P_1, P_2, P_3, P_4	4
P_3	(2,1)	P_1, P_2, P_3, P_4	4
P_4	(2,2)	P_1, P_2, P_3, P_4	4
P_5	(8,8)	P_5, P_6, P_8	3
P_6	(8,9)	P_5, P_6, P_8	3
P_7	(10,8)	P_7, P_8	2
P_8	(9,8)	P_5, P_6, P_7, P_8	4
P_9	(12,12)	P_9	1

2) Core / Border / Noise 분류

이웃이 3개 이상이면 core, core는 아니지만 어떤 core의 ε -이웃에 들어가면 border, 둘 다 아니면 noise 다.

P_1 부터 P_6 까지와 P_8 은 이웃이 3개 이상이므로 core point다. P_7 은 이웃이 2개라 core가 못 되지만 core인 P_8 과 거리가 1이라 P_8 의 이웃에 속하므로 border point다. P_9 는 자기 자신뿐이고 어떤 core의 이웃도 아니므로 noise point다.

구분	점
Core	$P_1, P_2, P_3, P_4, P_5, P_6, P_8$
Border	P_7
Noise	P_9

3) 최종 군집과 K를 정하지 않아도 되는 이유

core끼리 서로의 ε -이웃 관계로 연결된 것을 한 덩어리로 묶고, border는 자기를 이웃으로 갖는 core의 군집에 넣는다.

- 군집 1: $\{P_1, P_2, P_3, P_4\}$ — 넷 다 core이고 서로 직접 도달 가능하다.

- 군집 2: $\{P_5, P_6, P_7, P_8\}$ — P_5, P_6, P_8 이 core로 연결되고, P_7 은 core인 P_8 에서 도달 가능해 border로 포함된다. 단 P_7 은 core가 아니므로 P_7 을 거쳐 군집을 더 넓히지는 않는다.
- noise: $\{P_9\}$

결과적으로 군집 2개와 노이즈 1개가 나온다.

K-means는 목적함수 $\sum_k \sum_{x \in C_k} \|x - \mu_k\|^2$ 자체가 K 를 필요로 한다. 반면 DBSCAN이 받는 파라미터는 ϵ 과 **minPts**, 즉 "얼마나 촘촘해야 군집으로 볼 것인가"라는 밀도 기준이다. 아무 core point에서 출발해 밀도로 도달 가능한 점을 전부 흡수해 군집 하나를 만들고, 아직 안 본 core가 남아 있으면 새 군집을 시작하는 식으로 진행되므로 군집 개수는 입력이 아니라 결과로 나온다. 이 문제에서도 좌하단과 우상단 덩어리 사이가 ϵ 보다 훨씬 멀어서 자연스럽게 둘로 갈라졌다.

P_9 를 noise로 남겨 둘 수 있는 것도 같은 이유에서다. K-means였다면 P_9 도 어느 한쪽 군집에 억지로 들어가 centroid를 끌어당겼을 것이다.