



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시요. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

$$\lambda = 5, \lambda = 0$$

$$\lambda = 5, \lambda = 0$$

$$\lambda = 0.5$$

$$\begin{bmatrix} -1 & 2 \\ 2 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$\lambda = 0 \rightarrow$$

$$\begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

$$2x_1 + x_2 = 0$$

$$x_2 = -2x_1$$

$$\begin{bmatrix} \frac{1}{\sqrt{5}} \\ -\frac{2}{\sqrt{5}} \end{bmatrix}$$

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P는 직교행렬, D는 고윳값 대각행렬)

$$D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \quad P = \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ -\frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix} = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 & 1 \\ -1 & -2 \end{bmatrix} \quad P^T = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 & -1 \\ 1 & -2 \end{bmatrix} \quad A = \frac{1}{5} \begin{bmatrix} 2 & 1 \\ -1 & -2 \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 2 & -1 \\ 1 & -2 \end{bmatrix}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

$$\begin{aligned} & \text{PD: } x^T A x > 0, \det > 0, \text{ strictly convex} \quad \text{ND: } x^T A x < 0, \det < 0, -A \text{ is PD} \\ & \text{PSD: } x^T A x \geq 0, \det \geq 0, \text{ 중 0 有} \quad \text{NSD: } x^T A x \leq 0, \det \leq 0, \text{ 중 0 有, } -A \text{ is PSD} \end{aligned}$$

$$\lambda_1 = 5, \lambda_2 = 0 \rightarrow A: \text{PSD}$$

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1) $B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

$$\begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 9 & 1 \\ 1 & 9 \end{bmatrix} \quad \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \quad (9-\lambda)^2 - 4 = 0 \quad \begin{matrix} 9-\lambda=1 & \lambda=8 \\ 9-\lambda=7 & \lambda=2 \end{matrix} \quad \begin{matrix} \lambda_1=8 & \sigma_1=4 \\ \lambda_2=2 & \sigma_2=\sqrt{2} \end{matrix}$$

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3 개 나오며, 그중 가장 작은 고윳값은 0 이 됩니다.)

$$\begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix} \quad \begin{matrix} \lambda=0, 2, 16 \\ \lambda=16 & \sigma_1=4 \\ \lambda=2 & \sigma_2=\sqrt{2} \end{matrix} \quad \begin{matrix} \lambda=0 & u_3 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \\ \lambda=16 & u_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ \frac{1}{\sqrt{2}} \end{bmatrix} \\ \lambda=2 & u_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ -\frac{1}{\sqrt{2}} \end{bmatrix} \end{matrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U \Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0 인 3×2 직사각 대각행렬입니다.)

$$B = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$$\therefore \lambda = 8$$

$$\begin{pmatrix} -3 & 3 \\ 3 & 3 \end{pmatrix} \lambda_1 = \lambda_2 \begin{pmatrix} 1 \\ 1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$\therefore \lambda = 2$$

$$\begin{pmatrix} 3 & 3 \\ 3 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$$

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

$$(5-\lambda)^2 - 3^2 = 0$$

$$\lambda = 8, 2$$

1) Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

$$\lambda = 8 \rightarrow \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}, \lambda = 2 \rightarrow \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$$

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA 에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

$$PC1: \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \quad PC2: \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

$$\frac{8}{10} \quad 80\% \quad \frac{2}{10} \quad 20\%$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

20%, PC1 80%의 분산-정보는 유지되기 때문,

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

$$\begin{aligned} P(A) &= \frac{8}{16} = \frac{1}{2} \\ P(B) &= \frac{4}{16} = \frac{1}{4} \\ P(C) &= \frac{4}{16} = \frac{1}{4} \end{aligned}$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

$$H(X) = -\left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{4} \log_2 \frac{1}{4} + \frac{1}{4} \log_2 \frac{1}{4}\right) = -\left(-\frac{1}{2} - 1\right) = \frac{3}{2} \text{ bit}$$

3) 엔트로피의 최대값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$-3 \times \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3 \quad \text{왜냐하면 } 2^2=4 > 3 > 2^1=2 \text{ 이므로 } 1 < \log_2 3 < 2$$

현재 엔트로피는 엔트로피의 최대값에 가까워, 불확실성이 크다.

2-2: KL-Divergence

두 확률 분포 P 와 Q 가 다음과 같이 주어졌습니다.

$$\begin{aligned} D_{KL}(P||Q) &= 0.5 \log_2 \left(\frac{0.5}{0.25}\right) + 0.3 \log_2 \left(\frac{0.3}{0.5}\right) + 0.2 \log_2 \left(\frac{0.2}{0.25}\right) \\ &= -0.25 + 0.5 \times 0.1789 + 0.25 \times 0.3219 \\ &= 0.1989 \end{aligned}$$

X	A	B	C
P(X)	0.5	0.3	0.2
Q(X)	0.25	0.5	0.25

1) $D_{KL}(P||Q)$ 와 $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence가 $D_{KL}(P||Q) \neq D_{KL}(Q||P)$

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$ 기기라면서 같아야 함.

$$D_{KL}(P||Q) = 0.5 \log_2 \left(\frac{0.5}{0.25}\right) + 0.3 \log_2 \left(\frac{0.3}{0.5}\right) + 0.2 \log_2 \left(\frac{0.2}{0.25}\right) = 0.5 + 0.3(-0.5146) + 0.2(0.3219) = 0.2145$$

2) KL Divergence의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

두 확률분포가 모든 x에 대해 $P(x) = Q(x)$ 이면 $D_{KL}(P||Q) = 0$

3. Regression

3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 (n=5).

	-2	-1	0	1	2	
x	1	2	3	4	5	$\bar{x}=3$
y	2	3	5	6	9	$\bar{y}=5$
	-3	-2	0	1	4	

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

$$S_{xy} = 6 + 2 + 1 + 8 = 17 \quad S_{xx} = 4 + 1 + 1 + 4 = 10$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

$$\hat{\beta}_1 = 1.7 \quad \hat{\beta}_0 = 5 - 1.7 \times 3 = -0.1 \quad \hat{y} = 1.7x - 0.1$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1}{30} = \frac{29}{30}$$

$$\begin{aligned} x=1 \quad \hat{y}_1 &= 1.6 \rightarrow 0.4 & x=3 \quad \hat{y}_3 &= 5.1 \rightarrow 0 \\ x=5 \quad \hat{y}_5 &= 8.4 \rightarrow 0.6 & & \\ x=2 \quad \hat{y}_2 &= 2.3 \rightarrow -0.3 & x=4 \quad \hat{y}_4 &= 6.1 \rightarrow -0.1 \end{aligned} \quad \left| \begin{aligned} SSE &= 0.4^2 + 0.3^2 + 0.1^2 + 0.6^2 = 1.1 \\ SST &= 9 + 4 + 1 + 16 = 30 \end{aligned} \right.$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

$$R^2 = \frac{29}{30} \quad \text{1% 가깝게 잘 설명한다.}$$

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9로 계산되었습니다.

$$* VIF_i = \frac{1}{1 - R_i^2}$$

1) VIF 공식을 이용해 X_1 의 VIF 를 계산하세요.

$$\frac{1}{1-0.9} = \frac{1}{0.1} = 10$$

2) 위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

VIF가 10이면 다중공선성 문제 심각. X_2 or X_3 제거해야 해. VIF 너무 크면 X_1 은 제거..?

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3.5,4)
Class B (○): (5,5), (5,3), (6,4)

새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요

$$\begin{array}{l|l} \text{A (1,1)} & \sqrt{3^2+3^2} = 3\sqrt{2} \\ \text{(3.5,4)} & \sqrt{0.5^2} = 0.5 \end{array} \quad \begin{array}{l|l} \text{B (5,5)} & \sqrt{2^2+1^2} = \sqrt{5} \approx 2.24 \\ \text{(5,3)} & \sqrt{2^2} = \sqrt{2} \end{array}$$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

B

3) 거리의 역수 $w_i = \frac{1}{d(X_q, X_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

$$\frac{1}{0.5} = 2 > \frac{1}{\sqrt{5}} + \frac{1}{\sqrt{2}} = \frac{2}{\sqrt{5}} + \frac{1}{\sqrt{2}} \approx 1.4 \quad \text{A}$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

달라요 (3.5,4)가 (5,5)나 (5,3)보다 훨씬 가까운데
그런데 단순 다수결은 그렇지 않음

	P1 (2,3)	P2 (2,1)	P3 (3,2)	P4 (8,8)	P5 (9,8)	P6 (8,9)
C1(2,3)	0	2	$\sqrt{2}$	$\sqrt{61}$	$\sqrt{14}$	$\sqrt{12}$
C2(8,8)	$\sqrt{61}$	$\sqrt{65}$	$\sqrt{41}$	0	1	1
	↓	↓	↓	↓	↓	↓
	C1	C1	C1	C2	C2	C2

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)

초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

$$\left(\frac{2+2+3}{3}, \frac{3+1+2}{3} \right) = \left(\frac{7}{3}, 2 \right) \quad \left(\frac{8+9+8}{3}, \frac{8+8+9}{3} \right) = \left(\frac{25}{3}, \frac{25}{3} \right)$$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

$$C1 \left(\frac{7}{3}, 2 \right) \quad C2 \left(\frac{25}{3}, \frac{25}{3} \right)$$

$$\hookrightarrow \sqrt{6^2 + \left(\frac{19}{3}\right)^2} \approx \sqrt{116}$$

$$8 < d < 9$$

두 군집은 여전히 군집 내 범위보다 훨씬 커서 안 수렴. 5점.

5-2: DBSCAN

이웃을 탐색할 반경, ϵ

크기가 충분히 작기 위해 ϵ 는 너무 작아서는 안 되는 데이터 개수. (자신 포함)

다음과 같은 2 차원 데이터에 $\epsilon = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

2차원 데이터

$P_1(1,1)$, $P_2(1,2)$, $P_3(2,1)$, $P_4(2,2)$, $P_5(8,8)$, $P_6(8,9)$, $P_7(10,8)$, $P_8(9,8)$, $P_9(12,12)$

1) 각 점에 대해 ϵ 반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가 ϵ 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

$P_1: P_1, P_2, P_3, P_4 \checkmark$ $P_2: P_1, P_2, P_3, P_4 \checkmark$ $P_3: P_1, P_2, P_3, P_4 \checkmark$ $P_4: P_1, P_2, P_3, P_4 \checkmark$ $P_5: P_5, P_6, P_8 \checkmark$ $P_6: P_5, P_6, P_8 \checkmark$ $P_7: P_7, P_8 \checkmark$ $P_8: P_5, P_6, P_7, P_8 \checkmark$ $P_9: P_9$
 $P_2: P_1, P_2, P_3, P_4 \checkmark$ $P_4: P_1, P_2, P_3, P_4 \checkmark$ $P_6: P_5, P_6, P_8 \checkmark$ $P_8: P_5, P_6, P_7, P_8 \checkmark$

2) minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

Core Point: $P_1, P_2, P_3, P_4, P_5, P_6, P_8$, border: P_7 , Noise: P_9

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

P_1, P_2, P_3, P_4 / P_5, P_6, P_7, P_8

보통의 클러스터링 알고리즘은 군집 개수를 사전에 지정하기 때문이다.

Reference

- 26-2 Math for DS (15 기 김시원)
- 26-2 ML-supervised learning (15 기 조유빈)
- 26-2 ML-unsupervised learning (15 기 현승원)

Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원