

1. Linear Algebra

1-1: 고윳값 분해

1) 고윳값과 단위 고유벡터

특성방정식:

$$\det(A - \lambda I) = (4 - \lambda)(1 - \lambda) - 4 = \lambda^2 - 5\lambda = \lambda(\lambda - 5) = 0$$

$\therefore$ 고윳값: $\lambda_1 = 5, \lambda_2 = 0$

$\lambda_1 = 5 : (A - 5I)x = 0 \rightarrow -x_1 + 2x_2 = 0 \rightarrow x = (2, 1)^T$ 방향

$$v_1 = (2/\sqrt{5}, 1/\sqrt{5})^T$$

$\lambda_2 = 0 : Ax = 0 \rightarrow 4x_1 + 2x_2 = 0 \rightarrow x = (1, -2)^T$ 방향

$$v_2 = (1/\sqrt{5}, -2/\sqrt{5})^T$$

2) 대각화 $A = PDP^T$

$$P = (1/\sqrt{5}) \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix}, \quad D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}$$

즉,

$$A = (1/\sqrt{5}) \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix} \cdot \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \cdot (1/\sqrt{5}) \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix}^T$$

3) 정부호성 판별

고윳값이 $5 \geq 0, 0 \geq 0$ 으로 모두 0 이상이지만 0을 포함하므로 A는 PSD임.

4) (Optional) 직교대각화가 대칭행렬에서만 보장되는 이유

일반 정사각행렬은 서로 다른 고윳값에 대응하는 고유벡터들이 일차독립일 뿐, 내적이 0이라는 보장이 없음. 예를 들어 $\begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 의 고유벡터 $(1,0)^T, (1,1)^T$ 는 직교하지 않음.

반면 실수 대칭행렬은 스펙트럼 정리에 의해 (i) 모든 고윳값이 실수이고, (ii) 서로 다른 고윳값의 고유벡터가 자동으로 직교하며 — $\lambda_1 v_1^T v_2 = (Av_1)^T v_2 = v_1^T Av_2 = \lambda_2 v_1^T v_2$ 에서 $\lambda_1 \neq \lambda_2$ 이면 $v_1^T v_2 = 0$ — (iii) 중복 고윳값의 고유공간 내에서도 Gram-Schmidt로 정규직교기저를 잡을 수 있어, 항상 $A = PDP^T$ 형태의 직교대각화가 가능함.

1-2: 특잇값 분해

1) $B^T B$ 와 BB^T

$$B^T B = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix} \quad (2 \times 2)$$

$$BB^T = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix} \quad (3 \times 3)$$

2) V 와 특잇값

B^TB 의 특성방정식: $(9-\lambda)^2 - 49 = 0 \rightarrow \lambda = 16, 2$

$\lambda = 16$: 고유벡터 $(1, 1)^T$ 방향 $\rightarrow v_1 = (1/\sqrt{2}, 1/\sqrt{2})^T$

$\lambda = 2$: 고유벡터 $(1, -1)^T$ 방향 $\rightarrow v_2 = (1/\sqrt{2}, -1/\sqrt{2})^T$

$$V = (1/\sqrt{2}) \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

특잇값: $\sigma_1 = \sqrt{16} = 4, \sigma_2 = \sqrt{2} \approx 1.414$

3) U 구성

BB^T 의 고윳값: 16, 2, 0

$\lambda = 16$: $(1, 0, 1)^T$ 방향 $\rightarrow u_1 = (1/\sqrt{2}, 0, 1/\sqrt{2})^T$

$\lambda = 2$: $(0, 1, 0)^T \rightarrow u_2 = (0, 1, 0)^T$

$\lambda = 0$: $(1, 0, -1)^T$ 방향 $\rightarrow u_3 = (1/\sqrt{2}, 0, -1/\sqrt{2})^T$

$$U = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

4) $B = U\Sigma V^T$

$$\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \quad (3 \times 2)$$

$$B = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix} \cdot \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \cdot (1/\sqrt{2}) \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}^T$$

1-3: 주성분 분석(PCA)

1) 고윳값과 단위 고유벡터

특성방정식: $(5-\lambda)^2 - 9 = 0 \rightarrow \lambda = 8, 2$

$\lambda_1 = 8$: $v_1 = (1/\sqrt{2}, 1/\sqrt{2})^T, \lambda_2 = 2$: $v_2 = (1/\sqrt{2}, -1/\sqrt{2})^T$

2) 주성분 축

$PC1 = (1/\sqrt{2}, 1/\sqrt{2})^T$

$PC2 = (1/\sqrt{2}, -1/\sqrt{2})^T$

3) 설명 분산 비율

$$PC1: 8/(8+2) = 0.8, \quad PC2: 2/(8+2) = 0.2$$

4) 1차원 축소 시 손실

PC1만으로 축소하면 전체 분산 중 PC1이 설명하는 80%만 보존되고, PC2 방향의 분산에 해당하는 20%가 설명되지 않음. 근거: 각 주성분의 고윳값은 그 축 방향의 분산 크기와 같으므로, 버려진 축의 고윳값 비율 $2/10 = 20\%$ 가 곧 손실되는 분산 비율임. 손실이 20% 수준이므로 1차원 축소는 비교적 합리적인 선택이라고 해석 가능.

2. Information Theory

2-1: Entropy

1) 발생확률

$$P(A) = 8/16 = 1/2, \quad P(B) = 4/16 = 1/4, \quad P(C) = 4/16 = 1/4$$

2) 엔트로피

$$\begin{aligned} H(X) &= -(1/2)\log_2(1/2) - (1/4)\log_2(1/4) - (1/4)\log_2(1/4) \\ &= 1/2 \cdot 1 + 1/4 \cdot 2 + 1/4 \cdot 2 = 1.5 \text{ bits} \end{aligned}$$

3) 최대 엔트로피와의 비교

클래스가 3개이므로 최대 엔트로피는 모든 확률이 1/3로 동일할 때 $H_{\max} = \log_2 3 \approx 1.585$ bits임. 현재 엔트로피 1.5 bits는 최댓값에 상당히 가까우므로 불확실성이 높은 상태지만, A에 확률이 다소 쏠려 있어 완전 균등분포보다는 약간 낮음.

2-2: KL-Divergence

1) 양방향 KL 계산

$$\begin{aligned} D_{\text{KL}}(P||Q) &= 0.5 \cdot \log_2(0.5/0.25) + 0.3 \cdot \log_2(0.3/0.5) + 0.2 \cdot \log_2(0.2/0.25) \\ &= 0.5(1) + 0.3(-0.737) + 0.2(-0.322) \approx 0.2145 \text{ bits} \\ D_{\text{KL}}(Q||P) &= 0.25 \cdot \log_2(0.5) + 0.5 \cdot \log_2(0.5/0.3) + 0.25 \cdot \log_2(0.25/0.2) \\ &= -0.25 + 0.5(0.737) + 0.25(0.322) \approx 0.1990 \text{ bits} \end{aligned}$$

$D_{\text{KL}}(P||Q) \approx 0.2145 \neq 0.1990 \approx D_{\text{KL}}(Q||P)$. 거리는 대칭성 $d(x,y) = d(y,x)$ 를 만족해야 하는데 KL divergence는 두 방향의 값이 다르므로 대칭성을 위반하며, 삼각부등식도 일반적으로 성립하지 않음. 따라서 수학적 의미의 거리가 아님.

2) KL Divergence의 의미와 0이 되는 조건

$D_{\text{KL}}(P||Q)$ 는 실제 분포가 P일 때, P 대신 Q로 데이터를 부호화하면 추가로 필요해지는 평균 정보량임. 즉 Q가 P를 얼마나 잘 근사하는지를 나타내는 비대칭적 '차이' 측도임. $D_{\text{KL}}(P||Q) = 0$ 이 되는 조건은 모든 x 에 대해 $P(x) = Q(x)$ 인 경우, 즉 두 분포가 완전히 일치할 때뿐임.

3. Regression

3-1: 단순 선형 회귀

1) 평균과 S_{xy} , S_{xx}

$$\bar{x} = 3, \quad \bar{y} = 5$$

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	-2	-3	6	4
2	-1	-2	2	1
3	0	0	0	0
4	1	1	1	1
5	2	4	8	4
합			$S_{xy} = 17$	$S_{xx} = 10$

2) 회귀직선

$$\beta_1 = 17/10 = 1.7, \quad \beta_0 = 5 - 1.7 \times 3 = -0.1$$

$$\hat{y} = -0.1 + 1.7x$$

3) 잔차, SSE, SST, R²

x_i	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$	e_i^2
1	2	1.6	0.4	0.16
2	3	3.3	-0.3	0.09
3	5	5.0	0	0
4	6	6.7	-0.7	0.49
5	9	8.4	0.6	0.36

$$SSE = 1.10, \quad SST = 9 + 4 + 0 + 1 + 16 = 30$$

$$R^2 = 1 - SSE/SST = 1 - 1.1/30 \approx 0.9633$$

4) 해석

$R^2 \approx 0.963$ 은 y의 총 변동 중 약 96.3%가 회귀직선으로 설명됨을 의미함. 잔차도 모두 ± 0.7 이내로 작아, 이 회귀직선은 데이터를 매우 잘 설명한다고 평가할 수 있음.

3-2: 다중공선성 & VIF

1) VIF 계산

$$VIF_1 = 1 / (1 - R_1^2) = 1 / (1 - 0.9) = 10$$

2) 평가 및 변수 제거 여부

통상 $VIF > 10$ 이면 심각한 다중공선성으로 판단하는데, X1의 VIF가 정확히 10으로 기준선에 도달함. $R^2 = 0.9$ 라는 것은 X1의 변동 중 90%가 X2, X3로 설명된다는 뜻이므로 X1은 다른 변수들과 강한 선형관계

를 갖고, 회귀계수 추정치의 분산이 10배로 부풀려져 계수의 부호·크기 해석과 유의성 판단이 불안정해짐.

다만 제거를 기계적으로 결정할 일은 아님. (i) X_1 이 이론적으로 중요한 변수라면 제거 대신 Ridge/Lasso 같은 정규화, PCA, 변수 결합 등을 고려할 수 있고, (ii) 예측이 목적이라면 공선성이 예측 성능 자체에는 큰 문제가 아닐 수 있음. 반면 계수 해석이 목적이고 X_1 이 X_2 , X_3 와 정보가 중복된다면 제거할 만함.

4. Classification

4-1: KNN

1) 유클리드 거리

학습 데이터	클래스	$d(q, x_i)$	값
(1, 1)	A	$\sqrt{(3^2+3^2)} = \sqrt{18}$	≈ 4.243
(3.5, 4)	A	$\sqrt{(0.5^2+0^2)}$	0.5
(5, 5)	B	$\sqrt{(1^2+1^2)} = \sqrt{2}$	≈ 1.414
(5, 3)	B	$\sqrt{(1^2+1^2)} = \sqrt{2}$	≈ 1.414
(6, 4)	B	$\sqrt{(2^2+0^2)}$	2.0

2) K=3 단순 다수결

가장 가까운 3개: (3.5,4)[A, 0.5], (5,5)[B, $\sqrt{2}$], (5,3)[B, $\sqrt{2}$] → A 1표 vs B 2표 → 예측: Class B

3) Weighted KNN

$$w(A) = 1/0.5 = 2.000$$

$$w(B) = 1/\sqrt{2} + 1/\sqrt{2} = \sqrt{2} \approx 1.414$$

가중치 합: $A = 2.000 > B \approx 1.414$ → 예측: Class A

4) 두 결과 비교

단순 다수결은 B, weighted KNN은 A로 결과가 다름. 이유: $K=3$ 이웃 중 개수로는 B가 2개로 우세하지만, 거리 분포를 보면 A인 (3.5,4)는 q 에서 0.5로 매우 가깝고 B 이웃들은 $\sqrt{2} \approx 1.414$ 로 상대적으로 멀. 단순 다수결은 '몇 개인가'만 반영해 개수가 많은 B가 이기지만, 거리 역수 가중은 '얼마나 가까운가'를 반영해 압도적으로 가까운 A 이웃 하나가 B 이웃 둘의 합을 넘어섬. 이처럼 이웃 간 거리 편차가 클수록, 그리고 K 가 작을수록 두 방식의 결과가 달라질 가능성이 커짐.

5. Clustering

5-1: K-means 클러스터링

1) 초기 배정

점	$d(\cdot, C1=(2,3))$	$d(\cdot, C2=(8,8))$	배정
P1 (2,3)	0	$\sqrt{61} \approx 7.81$	C1
P2 (2,1)	2	$\sqrt{85} \approx 9.22$	C1
P3 (3,2)	$\sqrt{2} \approx 1.41$	$\sqrt{61} \approx 7.81$	C1
P4 (8,8)	$\sqrt{61} \approx 7.81$	0	C2
P5 (9,8)	$\sqrt{74} \approx 8.60$	1	C2
P6 (8,9)	$\sqrt{72} \approx 8.49$	1	C2

군집 1 = {P1, P2, P3}, 군집 2 = {P4, P5, P6}

2) 새로운 centroid

$$C1' = ((2+2+3)/3, (3+1+2)/3) = (7/3, 2) \approx (2.33, 2)$$

$$C2' = ((8+9+8)/3, (8+8+9)/3) = (25/3, 25/3) \approx (8.33, 8.33)$$

3) 재배정 및 수렴 판단

갱신된 centroid로 다시 거리를 계산해도 P1~P3은 여전히 C1'에, P4~P6은 여전히 C2'에 훨씬 가까움. 배정 결과가 이전 반복과 완전히 동일하므로 centroid도 더 이상 변하지 않고, 알고리즘은 수렴함.

5-2: DBSCAN

1) eps = 1.5 반경 내 이웃 수

점	eps 내 이웃	이웃 수
P1 (1,1)	P1, P2(1), P3(1), P4($\sqrt{2}$)	4
P2 (1,2)	P1, P2, P3($\sqrt{2}$), P4(1)	4
P3 (2,1)	P1, P2($\sqrt{2}$), P3, P4(1)	4
P4 (2,2)	P1($\sqrt{2}$), P2, P3, P4	4
P5 (8,8)	P5, P6(1), P8(1)	3
P6 (8,9)	P5(1), P6, P8($\sqrt{2}$)	3
P7 (10,8)	P7, P8(1)	2
P8 (9,8)	P5(1), P6($\sqrt{2}$), P7(1), P8	4
P9 (12,12)	P9	1

2) 점 분류 (minPts = 3)

Core point (이웃 수 ≥ 3): P1, P2, P3, P4, P5, P6, P8

Border point: P7 — 자신은 이웃이 2개뿐이지만 core point인 P8의 eps 반경 내에 있음

Noise point: P9 — 이웃이 자기 자신뿐이고 어떤 core point의 반경에도 속하지 않음

3) 최종 군집과 DBSCAN의 특징

군집 1 = {P1, P2, P3, P4}, 군집 2 = {P5, P6, P7, P8}, P9는 노이즈로 어느 군집에도 속하지 않음.

DBSCAN은 'eps 반경 안에 minPts 이상의 점이 있는가'라는 밀도 조건으로 core point를 찾고, 밀도로 연결된 core들을 따라 군집을 확장함. 군집은 이 밀도 연결 과정에서 자연스럽게 형성되고 그 개수는 데이터의 밀도 구조가 결정하므로, K-means처럼 군집 개수 K를 사전에 지정할 필요가 없음. 또한 어떤 군집에도 밀도 연결되지 않는 점을 노이즈로 분리할 수 있다는 점도 K-means와의 차이임.