

26-2 DSL 정규 세션

Part 1 과제



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트()를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주십시오. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

[답]

$$\begin{aligned} \det(A - \lambda I) &= (4 - \lambda)(1 - \lambda) - 4 = \lambda^2 - 5\lambda = \lambda(\lambda - 5) = 0 \\ \therefore \lambda_1 &= 5, \quad \lambda_2 = 0 \\ (A - 5I)x &= \begin{bmatrix} -1 & 2 \\ 2 & -4 \end{bmatrix} x = \mathbf{0} \Rightarrow x_1 = 2x_2 \Rightarrow \mathbf{v}_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 \\ 1 \end{bmatrix} \\ Ax = \mathbf{0} &\Rightarrow 2x_1 + x_2 = 0 \Rightarrow \mathbf{v}_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ -2 \end{bmatrix} \end{aligned}$$

2) 위 결과를 이용해 A 를 $A = PD P^T$ 형태로 대각화하세요. (P는 직교행렬, D는 고윳값 대각행렬)

[답]

$$P = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix}, \quad D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}$$

$$P D P^T = 5 \mathbf{v}_1 \mathbf{v}_1^T = 5 \cdot \frac{1}{5} \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix} = A$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

[답] 고윳값이 $\{5, 0\}$ 으로 모두 0 이상이고 0을 포함하므로 PSD (positive semi-definite)다.

$$\mathbf{x}^T A \mathbf{x} = 5(\mathbf{v}_1^T \mathbf{x})^2 \geq 0$$

이고 $\mathbf{x}$ 가 $\mathbf{v}_2$ 방향이면 0이 되므로 PD는 아니다.

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

[답] $\lambda \neq \mu$ 인 고유벡터 $\mathbf{u}, \mathbf{v}$ 에 대해 다음이 성립한다.

$$\lambda(\mathbf{u} \cdot \mathbf{v}) = (A\mathbf{u})^T \mathbf{v} = \mathbf{u}^T A^T \mathbf{v}$$

여기서 $A^T = A$ 일 때만 $\mathbf{u}^T A \mathbf{v} = \mu(\mathbf{u} \cdot \mathbf{v})$ 가 되어 $(\lambda - \mu)(\mathbf{u} \cdot \mathbf{v}) = 0$, 즉 $\mathbf{u} \cdot \mathbf{v} = 0$ 을 얻는다. 직교성은 A 가 대칭이라는 조건에서 나오므로 비대칭 행렬에는 보장이 없다.

예로 $\begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 의 고유벡터 $(1,0)^T, (1,1)^T$ 은 직교하지 않는다. 회전행렬처럼 고윳값이 복소수가 되거나, 고유벡터 수가 부족해 대각화 자체가 불가능한 경우도 있다.

실대칭행렬은 스펙트럼 정리에 따라 고윳값이 모두 실수이고 중복 고윳값에서도 기하적 중복도와 대수적 중복도가 같다. 따라서 항상 n개의 정규직교 고유벡터를 잡을 수 있고 직교대각화가 언제나 가능하다.

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1) $B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

[답]

$$B^T B = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix}$$

$$BB^T = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

[답] $\begin{bmatrix} a & b \\ b & a \end{bmatrix}$ 꼴이므로 고윳값은 $a \pm b$, 고유벡터는 $(1, 1)^T$ 과 $(1, -1)^T$ 이다.

$$\lambda_1 = 9 + 7 = 16, \quad \lambda_2 = 9 - 7 = 2$$

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \sigma_1 = \sqrt{16} = 4, \quad \sigma_2 = \sqrt{2} \approx 1.414$$

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3 개 나오며, 그중 가장 작은 고윳값은 0 이 됩니다.)

[답] BB^T 의 고윳값은 $B^T B$ 와 0이 아닌 부분이 같고 3×3 이므로 0이 하나 더 붙어 $\{16, 2, 0\}$ 이다.

$$\lambda = 16: x_1 = x_3, x_2 = 0 \Rightarrow \mathbf{u}_1 = \frac{1}{\sqrt{2}}(1, 0, 1)^T$$

$$\lambda = 2: x_1 = x_3 = 0 \Rightarrow \mathbf{u}_2 = (0, 1, 0)^T$$

$$\lambda = 0: x_3 = -x_1, x_2 = 0 \Rightarrow \mathbf{u}_3 = \frac{1}{\sqrt{2}}(1, 0, -1)^T$$

$$U = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U\Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각 원소가 σ_1, σ_2 이고 나머지는 0 인 3×2 직사각 대각행렬입니다.)

[답]

$$\begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}$$

V 가 대칭이므로 $V^T = V$ 다. Σ 의 3행이 0인 것은 $\text{rank}(B) = 2 < 3$ 이기 때문이다.

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1) Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

[답]

$$\det(\Sigma - \lambda I) = (5 - \lambda)^2 - 9 = 0 \Rightarrow 5 - \lambda = \pm 3 \Rightarrow \lambda_1 = 8, \lambda_2 = 2$$

$$\lambda_1 = 8: -3x_1 + 3x_2 = 0 \Rightarrow \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\lambda_2 = 2: 3x_1 + 3x_2 = 0 \Rightarrow \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

2) 위 결과를 이용해 제1 주성분(PC1)과 제2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA에서는 가장 큰 고윳값에 대응하는 고유벡터가 제1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제2 주성분(PC2)입니다.)

[답]

$$\text{PC1} = \frac{1}{\sqrt{2}} (1, 1)^T (\lambda_1 = 8), \quad \text{PC2} = \frac{1}{\sqrt{2}} (1, -1)^T (\lambda_2 = 2)$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

[답] 전체 분산은 $\text{tr}(\Sigma) = \lambda_1 + \lambda_2 = 5 + 5 = 10$ 이다.

$$\text{EVR}_1 = \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{8}{10} = 0.8 \text{ (80\%)}$$

$$\text{EVR}_2 = \frac{\lambda_2}{\lambda_1 + \lambda_2} = \frac{2}{10} = 0.2 \text{ (20\%)}$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

[답] 설명되지 않는 분산의 비율은 20%다.

PCA의 재구성 오차는 버린 성분의 고윳값 합과 같다. PC1만 남기면 $\lambda_2 = 2$ 만큼을 잃고, 그 비율은

$$\frac{\lambda_2}{\lambda_1 + \lambda_2} = \frac{2}{10} = 0.2 \text{ 이다.}$$

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

[답]

$$P(A) = \frac{8}{16} = 0.5, \quad P(B) = \frac{4}{16} = 0.25, \quad P(C) = \frac{4}{16} = 0.25$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

[답]

$$\begin{aligned} H(X) &= -[P(A) \log_2 P(A) + P(B) \log_2 P(B) + P(C) \log_2 P(C)] \\ &= -[0.5(-1) + 0.25(-2) + 0.25(-2)] = 0.5 + 0.5 + 0.5 \\ &\therefore H(X) = 1.5 \end{aligned}$$

3) 엔트로피의 최댓값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

[답] 최대 엔트로피는 세 클래스의 확률이 모두 $1/3$ 일 때이므로

$$\log_2 3 \approx 1.585, \quad \frac{1.5}{1.585} \approx 0.946$$

현재 엔트로피는 최댓값의 약 94.6% 수준이다. 불확실성이 높아 분포만 보고 클래스를 맞추기 어렵다.

2-2: KL-Divergence

두 확률 분포 P 와 Q 가 다음과 같이 주어졌습니다.

X	A	B	C
P(X)	0.5	0.3	0.2
Q(X)	0.25	0.5	0.25

1) $D_{KL}(P \parallel Q)$ 와 $D_{KL}(Q \parallel P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence 가 거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P \parallel Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

[답]

$$\begin{aligned}
 D_{KL}(P \parallel Q) &= 0.5 \log_2 \frac{0.5}{0.25} + 0.3 \log_2 \frac{0.3}{0.5} + 0.2 \log_2 \frac{0.2}{0.25} \\
 &= 0.5 - 0.2211 - 0.0644 = 0.2145 \\
 D_{KL}(Q \parallel P) &= 0.25 \log_2 \frac{0.25}{0.5} + 0.5 \log_2 \frac{0.5}{0.3} + 0.25 \log_2 \frac{0.25}{0.2} \\
 &= -0.25 + 0.3685 + 0.0805 = 0.1990
 \end{aligned}$$

거리의 공리는 비음수성, $d = 0 \Leftrightarrow$ 동일, 대칭성, 삼각부등식이다. 위에서 $0.2145 \neq 0.1990$ 이므로 대칭성이 깨지고, 삼각부등식도 일반적으로 성립하지 않는다. 그래서 metric이 아니라 divergence로 부른다.

2) KL Divergence 의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P \parallel Q) = 0$ 이 되는 조건을 설명하세요.

[답] 참 분포 P를 근사분포 Q로 부호화할 때 추가로 드는 평균 비트 수다.

$$D_{KL}(P \parallel Q) = H(P, Q) - H(P)$$

$H(P)$ 는 모델과 무관한 상수이므로, 분류 모델에서 cross-entropy loss를 최소화하는 것은 KL을 최소화하는 것과 같다.

0이 되는 조건은 모든 x에 대해 $P(x) = Q(x)$, 즉 두 분포가 완전히 같을 때이며 그때뿐이다. log가 오목함수이므로 Jensen 부등식에서

$$-D_{KL}(P \parallel Q) = \sum_x P(x) \log \frac{Q(x)}{P(x)} \leq \log \sum_x Q(x) = \log 1 = 0$$

즉 $D_{KL} \geq 0$ 이고(Gibbs 부등식), 등호는 $\frac{Q(x)}{P(x)}$ 가 상수일 때만 성립한다. 두 분포 모두 합이 1이므로 그 상수는 1이고 결국 $P = Q$ 가 된다.

3. Regression

3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 (n=5).

x	1	2	3	4	5
y	2	3	5	6	9

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

[답] $\bar{x} = \frac{15}{5} = 3$, $\bar{y} = \frac{25}{5} = 5$

$$S_{xy} = 17, \quad S_{xx} = 10$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

[답]

$$\hat{\beta}_1 = \frac{17}{10} = 1.7, \quad \hat{\beta}_0 = 5 - 1.7 \cdot 3 = -0.1$$
$$\therefore \hat{y} = -0.1 + 1.7x$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

[답]

$$SSE = 1.10, \quad SST = 30, \quad SSR = 28.90$$
$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.10}{30} = 0.9633$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

[답] $R^2 = 0.963$ 이므로 y의 전체 변동 중 약 96.3%를 회귀직선이 설명하므로 잘 설명하고 있다고 볼 수 있다.

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해 X1 의 VIF 를 계산하세요.

[답]

$$VIF_1 = \frac{1}{1 - R_1^2} = \frac{1}{1 - 0.9} = \frac{1}{0.1} = 10$$

2) 위 결과를 근거로 X1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

[답] $VIF = 10$ 은 X1 회귀계수의 분산이 다중공선성이 없을 때보다 10배 커졌다는 뜻이다. 통상 $VIF > 5$ 를 주의, $VIF \geq 10$ 을 심각으로 보므로 X1은 기준상 심각한 수준이다.

그러나 기계적으로 제거하는 것은 바람직하지 않다. 다중공선성은 계수 추정의 분산만 키울 뿐 추정량의 불편성이나 예측 성능은 훼손하지 않는다. 목적이 예측이라면 그대로 두어도 되고, 각 변수의 개별 효과를 해석하려는 경우에만 실질적인 문제가 된다. 또 X1이 이론적으로 반드시 포함되어야 하는 변수라면 제거가 오히려 누락변수 편향을 만들어 더 나쁜 결과를 낳는다.

따라서 도메인 지식으로 X2, X3와 개념적으로 중복되는지 먼저 확인해 중복이면 하나만 남기거나 합성 지표로 통합하고, 변수를 유지해야 하면 Ridge 회귀로 계수 분산을 줄이거나 PCA로 직교화한다. 상호작용항이나 다항항 때문이라면 중심화만으로 VIF가 크게 내려가는 경우가 많고, 표본 크기를 늘리면 표준오차 자체가 줄어 문제가 완화된다.

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A(●): (1,1), (3.5,4)

Class B(○): (5,5), (5,3), (6,4)

새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN 으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요

[답] $d(q, \mathbf{x}) = \sqrt{(4 - x_1)^2 + (4 - x_2)^2}$ 로 계산한다.

점	계산	거리
(1, 1)	$\sqrt{3^2 + 3^2} = \sqrt{18}$	4.2426
(3.5, 4)	$\sqrt{0.5^2 + 0^2}$	0.5000
(5, 5)	$\sqrt{1^2 + 1^2} = \sqrt{2}$	1.4142
(5, 3)	$\sqrt{1^2 + 1^2} = \sqrt{2}$	1.4142
(6, 4)	$\sqrt{2^2 + 0^2}$	2.0000

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

[답]

(3.5,4)A, (5,5)B, (5,3)B 이므로 A 1개, B 2개이다. → 예측 : Class B

3) 거리의 역수 $w_i = \frac{1}{d(\mathbf{x}_q, \mathbf{x}_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

[답]

이웃	클래스	d	$w = 1/d$
(3.5, 4)	A	0.5	2.0000
(5, 5)	B	1.4142	0.7071
(5, 3)	B	1.4142	0.7071

$$W_A = \frac{1}{0.5} = 2.0000, \quad W_B = \frac{1}{1.4142} + \frac{1}{1.4142} = 1.4142$$

$$W_A > W_B \Rightarrow \text{Class A}$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

[답] 단순 다수결은 Class B, weighted KNN은 Class A로 두 결과가 다르다.

원인은 이웃까지의 거리가 고르지 않기 때문이다. A의 이웃 (3.5, 4)는 거리가 0.5이고 B의 두 이웃은 그보다 약 2.8배 먼 1.4142다. 단순 다수결은 거리를 반영하지 않고 개수만 세므로 B가 나오고, $1/d$ 로 가중하면 $2.0 > 1.4142$ 가 되어 A가 나온다.

K 값에 따라서도 결과가 바뀐다. $K = 1$ 이면 최근접이 (3.5, 4) 이므로 A, $K = 3$ 이면 다수결은 B이고 가중은 A, $K = 5$ 면 A 2표 대 B 3표로 다시 B다. A는 q 근처에 있지만 학습 데이터가 2개뿐이라 K를 키우면 개수가 많은 B가 이긴다. 클래스별 데이터 수가 다를 때 K가 크면 단순 다수결은 데이터가 많은 클래스 쪽으로 치우친다.

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

$$P_1(2,3), P_2(2,1), P_3(3,2), P_4(8,8), P_5(9,8), P_6(8,9)$$

$$\text{초기 centroid: } C_1 = (2,3), \quad C_2 = (8,8)$$

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

[답]

$$\text{Cluster 1} = \{P_1, P_2, P_3\}, \quad \text{Cluster 2} = \{P_4, P_5, P_6\}$$

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

[답]

$$C_1' = \left(\frac{2+2+3}{3}, \frac{3+1+2}{3} \right) = \left(\frac{7}{3}, 2 \right) \approx (2.333, 2.000)$$
$$C_2' = \left(\frac{8+9+8}{3}, \frac{8+8+9}{3} \right) = \left(\frac{25}{3}, \frac{25}{3} \right) \approx (8.333, 8.333)$$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

[답]

$$\text{Cluster 1} = \{P_1, P_2, P_3\}, \quad \text{Cluster 2} = \{P_4, P_5, P_6\}$$

배정 결과가 1차와 같으므로 centroid도 더 이상 변하지 않는다. 알고리즘은 수렴했다.

5-2: DBSCAN

다음과 같은 2 차원 데이터에 $\text{eps} = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

$$P_1(1,1), P_2(1,2), P_3(2,1), P_4(2,2), P_5(8,8), P_6(8,9), P_7(10,8), P_8(9,8), P_9(12,12)$$

1) 각 점에 대해 eps 반경 내 이웃의 개수를 계산하세요.

(💡 힌트: 두 점 사이의 거리가 eps 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

[답]

점	eps 내 이웃	개수
$P_1(1,1)$	P_1, P_2, P_3, P_4	4
$P_2(1,2)$	P_1, P_2, P_3, P_4	4
$P_3(2,1)$	P_1, P_2, P_3, P_4	4
$P_4(2,2)$	P_1, P_2, P_3, P_4	4
$P_5(8,8)$	P_5, P_6, P_8	3
$P_6(8,9)$	P_5, P_6, P_8	3
$P_7(10,8)$	P_7, P_8	2
$P_8(9,8)$	P_5, P_6, P_7, P_8	4
$P_9(12,12)$	P_9	1

2) minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

[답]

점	이웃 수	판정	근거
$P_1 \sim P_4$	4	core	$4 \geq 3$
P_5, P_6	3	core	$3 \geq 3$
P_8	4	core	$4 \geq 3$
P_7	2	border	minPts 미만이나 core인 P_8 의 이웃
P_9	1	noise	minPts 미만이고 어떤 core의 이웃도 아님

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

[답] core point 사이의 density-connectivity를 따라 군집을 확장한다. P1부터 P4는 서로 직접 도달 가능하고, 오른쪽은 P5, P6, P8이 core끼리 연결된 뒤 P8이 border인 P7을 흡수한다.

Cluster 1 = $\{P_1, P_2, P_3, P_4\}$

Cluster 2 = $\{P_5, P_6, P_7, P_8\}$

Noise = $\{P_9\}$

K-means는 목적함수 자체가 K개 centroid까지의 SSE 최소화로 정의되므로 K가 없으면 문제가 성립하지 않는다. 군집 수는 알고리즘의 입력이다.

반면 DBSCAN은 군집을 밀도가 임계치를 넘는 영역들의 연결 성분으로 정의한다. 사용자가 지정하는 것은 밀도 기준인 eps와 minPts뿐이고, 알고리즘은 core point 사이의 density-reachability를 그래프로 보아 연결 성분을 센다. 군집 개수는 데이터의 밀도 구조에 따라 정해지는 출력이다. 위에서도 개수를 지정하지 않았지만 밀집 영역이 둘로 나뉘어 2개가 나왔다.

Reference

- 26-2 Math for DS (15 기 김시원)
- 26-2 ML-supervised learning (15 기 조유빈)
- 26-2 ML-unsupervised learning (15 기 현승원)

Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원