

## 26-2 DSL 정규 세션

## Part 1 과제



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시요. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

## 1. Linear Algebra

## 1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식  $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해  $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

$$\begin{aligned} \det(A - \lambda I) &= \begin{vmatrix} 4-\lambda & 2 \\ 2 & 1-\lambda \end{vmatrix} = 4 - \lambda + \lambda^2 - 4 = \lambda^2 - \lambda = 0 \\ \therefore \lambda &= 0 \quad A\mathbf{x} = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad \begin{matrix} 4x_1 + 2x_2 = 0 \\ 2x_1 + x_2 = 0 \end{matrix} \quad \begin{matrix} \Rightarrow x_2 = -2x_1 \\ \Rightarrow x_2 = -2x_1 \end{matrix} \\ \|\begin{pmatrix} 1, -2 \end{pmatrix}\| &= \sqrt{5} \\ \therefore \mathbf{v}_1 &= \left( \frac{1}{\sqrt{5}}, \frac{-2}{\sqrt{5}} \right) \end{aligned}$$

2) 위 결과를 이용해 A 를  $A = PDP^T$  형태로 대각화하세요. (P는 직교행렬, D는 고윳값 대각행렬)

$$\begin{aligned} P &= \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix} \quad D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \quad A P = P D, \quad P^{-1} = P^T \\ A &= P D P^{-1} = \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \end{bmatrix} \end{aligned}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

$$\lambda_1 = 0, \quad \lambda_2 = 5 > 0$$

$$\therefore A \in \text{PSD}$$

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

## 1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1)  $B^T B$  ( $2 \times 2$ )와  $BB^T$  ( $3 \times 3$ )를 각각 계산하세요.

$$1) \quad B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

$$B^T = \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix}$$

$$B^T B = \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix}$$

$$BB^T = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2)  $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values)  $\sigma_1, \sigma_2$ 를 구하세요. ( $\sigma_1 > \sigma_2$ )

3)  $BB^T$ 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. ( $BB^T$ 는  $3 \times 3$  이므로 고윳값이 3 개 나오며, 그중 가장 작은 고윳값은 0 이 됩니다.)

4) 위에서 구한 U ( $3 \times 3$ ),  $\Sigma$  ( $3 \times 2$ ), V ( $2 \times 2$ )를 이용해  $B = U \Sigma V^T$  형태로 명시하세요. ( $\Sigma$ 는 주대각원소가  $\sigma_1, \sigma_2$ 이고 나머지는 0 인  $3 \times 2$  직사각 대각행렬입니다.)

2)

$$B^T B = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix} = A$$

$$\det(A - \lambda I) = \begin{vmatrix} 9-\lambda & 7 \\ 7 & 9-\lambda \end{vmatrix} = 9^2 - 16\lambda + \lambda^2 = 0$$

$$\lambda_1 = 16, \lambda_2 = 2$$

$$\therefore \lambda = 16$$

$$\begin{bmatrix} -7 & 7 \\ 7 & -7 \end{bmatrix} x = 0, \quad x_1 = x_2$$

$$\|(1, 1)\| = \sqrt{2}, \quad v_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$$

$$ii) \lambda = 2$$

$$\begin{bmatrix} 7 & 7 \\ 7 & 7 \end{bmatrix} x = 0, \quad x_1 = -x_2$$

$$\|(1, -1)\| = \sqrt{2}, \quad v_2 = \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)$$

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$$b_1 = \sqrt{16} = 4$$

$$b_2 = \sqrt{2}$$

3)

$$BB^T = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

$$\det(BB^T - \lambda I) = \begin{vmatrix} 8-\lambda & 0 & 8 \\ 0 & 2-\lambda & 0 \\ 8 & 0 & 8-\lambda \end{vmatrix} = (2-\lambda)(64-16\lambda+\lambda^2-64) = (2-\lambda)(\lambda^2-16)$$

$$\therefore \lambda_1 = 16, \lambda_2 = 2, \lambda_3 = 0$$

$$i) \lambda_1 = 16, \quad u_1 = \left(\frac{1}{\sqrt{2}}, 0, \frac{1}{\sqrt{2}}\right)$$

$$ii) \lambda_2 = 2, \quad u_2 = (0, 1, 0)$$

$$iii) \lambda_3 = 0, \quad u_3 = \left(\frac{1}{\sqrt{2}}, 0, -\frac{1}{\sqrt{2}}\right)$$

$$\therefore U = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$$4) \quad \Sigma = \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

$$B = U \Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

### 1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬  $\Sigma$  가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1)  $\Sigma$  의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

$$\det(\Sigma - \lambda I) = \begin{vmatrix} 5-\lambda & 3 \\ 3 & 5-\lambda \end{vmatrix} = (5-\lambda)^2 - 9 = 0 \quad \begin{matrix} i) \lambda_1 = 8 \\ [3 \ 3] x = 0 \\ x_1 = x_2 = \frac{1}{\sqrt{2}} \end{matrix} \quad \begin{matrix} ii) \lambda_2 = 2 \\ [3 \ -3] x = 0 \\ x_1 = -x_2 = \frac{1}{\sqrt{2}} \end{matrix}$$

$\lambda_1 = 8, \lambda_2 = 2$

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA 에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

$$PC1 = v_1 = \left( \frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right)$$

$$PC2 = v_2 = \left( \frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}} \right)$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

$$\text{전체 분산} = \lambda_1 + \lambda_2 = 10$$

$$EVR_{PC1} = \frac{8}{10} = 0.8 = 80\%, \quad EVR_{PC2} = \frac{2}{10} = 20\%$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

$$0.2 \quad (20\%)$$

$$EVR_{PC2} = 0.2 \quad 0.22$$

## 2. Information Theory

### 2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

| 클래스 | 개수 |
|-----|----|
| A   | 8  |
| B   | 4  |
| C   | 4  |

1) 각 클래스의 발생확률  $P(A)$ ,  $P(B)$ ,  $P(C)$ 를 구하세요

$$P(A) = \frac{1}{2}, \quad P(B) = \frac{1}{4}, \quad P(C) = \frac{1}{4}$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요.  $H(X) = -\sum_x P(x) \log_2 P(x)$

$$-\left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{4} \log_2 \frac{1}{4} \times 2\right) = -\left(-\frac{1}{2} - 1\right) = \frac{3}{2} = 1.5$$

3) 엔트로피의 최댓값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$-\left(3 \cdot \frac{1}{3} \log_2 \frac{1}{3}\right) = \log_2 3 \approx 1.585, \quad \text{현재 데이터 엔트로피는 최대 엔트로피 값에 미치지 못함.}$$

⇒ 데이터의 불확실성이 높은 편.

### 2-2: KL-Divergence

두 확률 분포 P와 Q가 다음과 같이 주어졌습니다.

| X    | A    | B   | C    |
|------|------|-----|------|
| P(X) | 0.5  | 0.3 | 0.2  |
| Q(X) | 0.25 | 0.5 | 0.25 |

1)  $D_{KL}(P||Q)$ 와  $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence가

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요.  $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

$$D_{KL}(P||Q) = 0.5 \log_2 2 + 0.3 \log_2 \frac{3}{5} + 0.2 \log_2 \frac{2}{5} \approx 0.216$$

$$D_{KL}(Q||P) \approx 0.199$$

$$\left. \begin{aligned} d(Q,P) &= d(P,Q) \text{ 여야 하는데} \\ D_{KL}(P||Q) &\neq D_{KL}(Q||P) \therefore \text{not symmetric} \end{aligned} \right\}$$

2) KL Divergence의 의미를 간단히 설명하세요. 그리고  $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

두 분포 P와 Q가 정확히 같을 때 발생하는 경우입니다.

$$D_{KL}(P||Q) = 0 \Leftrightarrow P(x) = Q(x) \text{ for } \forall x$$

### 3. Regression

#### 3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 (n=5).

|   |   |   |   |   |   |
|---|---|---|---|---|---|
| x | 1 | 2 | 3 | 4 | 5 |
| y | 2 | 3 | 5 | 6 | 9 |

1)  $\bar{x}$ ,  $\bar{y}$  를 구하고,  $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$ ,  $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$  를 계산하세요.

$$\bar{x} = 3 \quad S_{xy} = 2 + 6 + 15 + 24 + 45 - 5 \times 15 = 17$$

$$\bar{y} = 5 \quad S_{xx} = 1 + 4 + 9 + 16 + 25 - 5 \times 5 = 10$$

2)  $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$ ,  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$  공식을 이용해 회귀직선  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$  을 구하세요.

$$\hat{y} = \frac{1}{10} + \frac{17}{10}x$$

3) 각 관측치의 잔차  $e_i = y_i - \hat{y}_i$  와,  $SSE = \sum_{i=1}^n e_i^2$ ,  $SST = \sum_{i=1}^n (y_i - \bar{y})^2$  를 계산해  $R^2$ 을 구하세요.

$$\hat{y}_1 = 1.6, \hat{y}_2 = 2.9, \hat{y}_3 = 5, \hat{y}_4 = 6.7, \hat{y}_5 = 8.6$$

$$e_1 = 0.4, e_2 = -0.9, e_3 = 0, e_4 = -0.7, e_5 = 0.6$$

$$SSE = 1.1, SST = 30, R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.1}{30} \approx 0.963$$

4) 계산된  $R^2$ 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

약 96.3% 설명  $\Rightarrow$  매우 잘 설명하고 있음

#### 3-2: 다중공선성 & VIF

세 개의 입력변수  $X_1, X_2, X_3$  를 가진 다중선형회귀 모형에서,  $X_1$  을 나머지 두 변수( $X_2, X_3$ )로 회귀했을 때의  $R^2$ 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해  $X_1$  의 VIF 를 계산하세요.

$$\frac{1}{1 - 0.9} = \frac{1}{0.1} = 10$$

2) 위 결과를 근거로  $X_1$  의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

$VIF \geq 10 \Rightarrow$  다중공선성 문제 발생  $\Rightarrow$  변수 제거

## 4. Classification

### 4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3.5,4)  
Class B (○): (5,5), (5,3), (6,4)

새로운 데이터  $q=(4,4)$ 에 대해  $K=3$  인 KNN 으로 분류하고자 합니다.

$q=q$  (●)

1)  $q$  와 각 학습 데이터 간의 유클리드 거리를 계산하세요

$$\begin{aligned} A_1 &= (1,1), & d_{11} &= \sqrt{2} & B_1 &= (5,5), & d_{21} &= \sqrt{2} \\ A_2 &= (3.5,4), & d_{12} &= 0.5 & B_2 &= (5,3), & d_{22} &= \sqrt{2} \\ & & & & B_3 &= (6,4), & d_{23} &= 2 \end{aligned}$$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로  $q$  의 클래스를 예측하세요.

$$\begin{aligned} A_2 & \quad B_1 \quad B_2 \\ (3.5,4), & (5,5), (5,3) \\ & \therefore B \end{aligned}$$

3) 거리의 역수  $w_i = \frac{1}{d(X_q, X_i)}$  를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운  $K$  개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다.

이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

$$\begin{aligned} A_2 & \quad w_1 = 2 & w_A &= 2 \\ B_1 & \quad w_2 = \frac{1}{\sqrt{2}} & w_B &= \frac{2}{\sqrt{2}} = \sqrt{2} & \therefore A_2 \text{가 정답} \\ B_2 & \quad w_3 = \frac{1}{\sqrt{2}} \end{aligned}$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를  $K$  값 및 이웃과의 거리 분포 관점에서 설명하세요.

$K$ 가 작을 때  
단순 다수결은 이웃이 얼마나 가까운지 모르기 때문에

## 5. Clustering

### 5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)  
초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

$$C_1 \Rightarrow P_1, P_2, P_3$$

$$C_2 \Rightarrow P_4, P_5, P_6$$

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

$$C_{new1} = \left( \frac{17}{3}, 2 \right)$$

$$C_{new2} = \left( \frac{25}{3}, \frac{25}{3} \right)$$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

$$C_1 \Rightarrow P_1, P_2, P_3$$

$$C_2 \Rightarrow P_4, P_5, P_6$$

배정변화 X  
∴ 알고리즘 수렴

## 5-2: DBSCAN

다음과 같은 2 차원 데이터에  $\text{eps} = 1.5$ ,  $\text{minPts} = 3$  을 적용합니다.

$P1(1,1)$ ,  $P2(1,2)$ ,  $P3(2,1)$ ,  $P4(2,2)$ ,  $P5(8,8)$ ,  $P6(8,9)$ ,  $P7(10,8)$ ,  $P8(9,8)$ ,  $P9(12,12)$

1) 각 점에 대해  $\text{eps}$  반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가  $\text{eps}$  이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

$P_1: P_2, P_3, P_4 \rightarrow 4\text{개}$        $P_5: 7\text{개}$        $P_8: 4\text{개}$   
 $P_2: 4\text{개}$        $P_6: 7\text{개}$        $P_9: 1\text{개}$   
 $P_3: 4\text{개}$        $P_7: 2\text{개}$   
 $P_4: 4\text{개}$

2)  $\text{minPts}$  기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

core point:  $P_1, P_2, P_3, P_4, P_5, P_6, P_8$   
border point:  $P_7$   
noise point:  $P_9$

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

Cluster 1 =  $\{P_1, P_2, P_3, P_4\}$

Cluster 2 =  $\{P_5, P_6, P_7, P_8\}$

Noise:  $P_9$

임의 개수로 임의의 높은 부분으로 결정하는 것이 좋음

### Reference

- 26-2 Math for DS (15 기 김시원)
- 26-2 ML-supervised learning (15 기 조유빈)
- 26-2 ML-unsupervised learning (15 기 현승원)

### Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원