

26-2 DSL 정규 세션

Part 1 과제



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시요. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

$$\lambda^2 - 5\lambda, \lambda_1 = 5, \lambda_2 = 0.$$

$$\hookrightarrow v_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \hookrightarrow \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P 는 직교행렬, D 는 고윳값 대각행렬)

$$\frac{1}{5} \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

$$\hookrightarrow \text{PSD} \text{ 이므로}$$

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1) $B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

$$\begin{bmatrix} 9 & 1 \\ 1 & 9 \end{bmatrix} \quad \begin{bmatrix} 8 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 8 \end{bmatrix}$$

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

$$\lambda_1 = 10, \lambda_2 = 2, \quad v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3개 나오며, 그중 가장 작은 고윳값은 0이 됩니다.)

$$U = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \end{bmatrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U \Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0인 3×2 직사각 대각행렬입니다.)

$$\begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1) Σ 의 고유값과 각 고유값에 대응하는 단위 고유벡터를 구하세요.

Handwritten solution for step 1:

$$\lambda_1, \lambda_2 \rightarrow \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA에서는 가장 큰 고유값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고유값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

Handwritten solution for step 2:

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix} \rightarrow 80\% \quad \begin{bmatrix} 1 \\ -1 \end{bmatrix} \rightarrow 20\%$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

Handwritten answer for step 4:

PC1의 축하면 전체 분산중 PC2가 설명하던 20% 분산 설명.

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

$$\begin{array}{ccc} \downarrow & \downarrow & \downarrow \\ 0.5 & 0.25 & 0.25 \end{array}$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

$$= 1.5$$

3) 엔트로피의 최댓값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$\text{최대 엔트로피: } \log_2 4 \approx 1.785$$

2-2: KL-Divergence

두 확률 분포 P 와 Q 가 다음과 같이 주어졌습니다.

X	A	B	C
$P(X)$	0.5	0.3	0.2
$Q(X)$	0.25	0.5	0.25

1) $D_{KL}(P||Q)$ 와 $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence 가

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

$$\begin{array}{ccc} \downarrow & \downarrow & \downarrow \\ 0.219 & 0.199 & \text{두 값이 서로 다르기 때문에 } D_{KL}(P||Q) \neq D_{KL}(Q||P) \end{array}$$

2) KL Divergence 의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

상호 정보량 거리를 의미하며, 두 분포가 동일할 때 $D_{KL} = 0$ 이다. 이 때문이다.

3. Regression

3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 (n=5).

x	1	2	3	4	5
y	2	3	5	6	9

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

$$\begin{array}{ccc} \downarrow \downarrow & \downarrow & \downarrow \\ 2 & 1.7 & 10 \end{array}$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

$$\begin{array}{cc} \downarrow & \downarrow \\ 1.7 & -0.1 \end{array}$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

$$\begin{array}{ccccccc} \downarrow & & \downarrow & & \downarrow & & \downarrow \\ 0.4, -0.3, 0, -0.7, 0.6 & 1.1 & 20 & & 1 - \frac{1.1}{20} = 0.945 \end{array}$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

회귀직선이 데이터의 94.5%를 설명하고 있다.

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해 X_1 의 VIF 를 계산하세요.

$$\hookrightarrow \frac{1}{1-0.9} = 10$$

2) 위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

다중공선성이 꽤 강하게 존재하므로,
변수를 제거하는 것이 필요하다.

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3.5,4)
Class B (○): (5,5), (5,3), (6,4)

새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN 으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요

$$A_1(1,1), A_2(0.5), B_1(1,1), B_2(1,1), B_3(2)$$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

$$\underbrace{A_2, B_1, B_2}_{A}, \underbrace{B_2}_{B}$$

3) 거리의 역수 $w_i = \frac{1}{d(X_q, X_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

$$A \text{의 가중치 합: } \frac{1}{0.5} = 2. \quad B \text{의 가중치 합: } \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} = \sqrt{2}. \quad \text{class A.}$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 (다른지) 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

단순 다수결은 거리를 고려하지 않으나 Weighted KNN은
 A_2 가 Q 와 가깝기 때문에 가중치가 크게 반영되어서이다.

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)
초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

p_1, p_2, p_3 는 C_1 에, p_4, p_5, p_6 는 C_2 에 배정.

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

$C_{1new}: (2/3, 2)$ $C_{2new}: (25/3, 25/3)$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

~~~~~  
배정이 변하지 않으므로, 알고리즘 수렴!

## 5-2: DBSCAN

다음과 같은 2 차원 데이터에  $\text{eps} = 1.5$ ,  $\text{minPts} = 3$  을 적용합니다.

$P1(1,1)$ ,  $P2(1,2)$ ,  $P3(2,1)$ ,  $P4(2,2)$ ,  $P5(8,8)$ ,  $P6(8,9)$ ,  $P7(10,8)$ ,  $P8(9,8)$ ,  $P9(12,12)$

1) 각 점에 대해  $\text{eps}$  반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가  $\text{eps}$  이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

↓  
 $P_1(4), P_2(4), P_3(4), P_4(4), P_5(3), P_6(3), P_7(1), P_8(4), P_9(1)$

2)  $\text{minPts}$  기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

↓                      ↓                      ↓  
 $P_1, P_2, P_3, P_4, P_5, P_6, P_8 \quad P_7 \quad P_9$

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

$K$ -means와 달리 밀도를 기준으로 한점 core point를 연결하여  
군집을 형성하므로 사전에 분류가 가능하다.

### Reference

- 26-2 Math for DS (15 기 김시원)  
- 26-2 ML-supervised learning (15 기 조유빈)  
- 26-2 ML-unsupervised learning (15 기 현승원)

### Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원