

26-2 DSL 정규 세션

Part 1 과제



- 본 과제는 학회 정규 세션 'Math for DS', 'ML-supervised learning', 'ML-unsupervised learning'의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시고, 단, 답안 표절이나 LLM의 남용은 금지합니다.
- 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시고, Github 에 제출하는 방법을 모른다면 학술팀장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

$$\det(A - \lambda I) = 0 \rightarrow 4 - 5\lambda + \lambda^2 - 4 = 0 \rightarrow \lambda(\lambda - 5) = 0, \lambda_1 = 0, \lambda_2 = 5$$

$$1) \lambda_1 = 0 \text{ 일때: } 4x + 2y = 0 \Rightarrow y = -2x, v_1 = \left(\frac{1}{\sqrt{5}}, \frac{2}{\sqrt{5}}\right) \quad 2) \lambda_2 = 5 \text{ 일때: } -2x + 2y = 0 \Rightarrow x = 2y, v_2 = \left(\frac{2}{\sqrt{5}}, \frac{1}{\sqrt{5}}\right)$$

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P는 직교행렬, D는 고윳값 대각행렬)

$$P = \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ -\frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{bmatrix}, D = \begin{bmatrix} 0 & 0 \\ 0 & 5 \end{bmatrix}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

$$\text{고윳값이 } 0 \text{ 과 } 5 > 0 \text{ 이므로, } \underline{\underline{PSD}}$$

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)하다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

→ 대칭행렬이 아닌 경우 고유벡터들의 내적이 0 이라는 보장 X

$$\rightarrow v_1^T A v_2 = v_1^T (\lambda_2 v_2) = \lambda_2 v_1^T v_2$$

$$v_1^T A v_2 = v_1^T A^T v_2 = (A v_1)^T v_2$$

$$= \lambda_1 v_1^T v_2$$

$$\rightarrow (\lambda_1 - \lambda_2) v_1^T v_2 = 0$$

$$\underline{\underline{v_1^T v_2 = 0}} \quad (\because \lambda_1 \neq \lambda_2)$$

↳ 직교

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}$$

1) $B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

$$B^T B = \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix}, \quad BB^T = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2) $B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

$$(9-\lambda)^2 - 49 = 0 \rightarrow \begin{cases} \lambda_1 = 16 : x=y \\ \lambda_2 = 2 : x=-y \end{cases} \Rightarrow V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \quad \begin{matrix} \sigma_1 = \sqrt{16} = 4 \\ \sigma_2 = \sqrt{2} \end{matrix}$$

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3개 나오며, 그중 가장 작은 고윳값은 0이 됩니다.)

$$\det = -0 \cdot C_{21} + (2-\lambda) M_{22} - 0 \cdot C_{23}$$

$$\hookrightarrow M_{22} = \det \begin{bmatrix} 8-\lambda & 8 \\ 8 & 8-\lambda \end{bmatrix} = (2-\lambda)[(8-\lambda)^2 - 64] = 0 \rightarrow \begin{cases} \lambda_1 = 16 : x=2, y=0 \\ \lambda_2 = 2 : x=0, y=0 \\ \lambda_3 = 0 : x=-2, y=0 \end{cases} \rightarrow U = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U \Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0인 3×2 직사각 대각행렬입니다.)

$$B = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1) Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

$$(5-\lambda)^2 - 9 = 0 \rightarrow \begin{cases} \lambda_1 = 8, & x = y, & (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}) \\ \lambda_2 = 2, & x = -y, & (\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}) \end{cases}$$

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

$$PC1 : (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$$

$$PC2 : (\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}})$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

$$PC1 : \frac{8}{10} \rightarrow 0.8$$

$$PC2 : \frac{2}{10} \rightarrow 0.2$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

$$\text{설명되지 않는 비율은 } 20\%$$

PC2이 대응하는 고윳값이 전체 분산에서 20%를 차지하기 때문.

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

$$P(A) = \frac{8}{16} = 0.5 \quad P(B) = \frac{4}{16} = 0.25 \quad P(C) = \frac{4}{16} = 0.25$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

$$H(X) = -0.5 \log_2 \frac{1}{2} + (-0.25) \log_2 \frac{1}{4} \cdot 2 = 1.5$$

3) 엔트로피의 최댓값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$H_{max} = -3 \cdot \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3 \approx 1.585$$

→ 최대 엔트로피와 같이 비슷하므로
데이터셋이 비교적 고르게 분포되어 있는,
클래스 예측이 상대적으로 어려운 불확실성이 높은
상태라고 볼 수 있다.

2-2: KL-Divergence

두 확률 분포 P와 Q가 다음과 같이 주어졌습니다.

X	A	B	C
P(X)	0.5	0.3	0.2
Q(X)	0.25	0.5	0.25

1) $D_{KL}(P||Q)$ 와 $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence가

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

$$D_{KL}(P||Q) = 0.5 \cdot \log_2 2 + 0.3 \cdot \log_2 0.6 + 0.2 \cdot \log_2 0.8 \approx 0.215$$

$$D_{KL}(Q||P) = 0.25 \cdot \log_2 0.5 + 0.5 \cdot \log_2 \frac{5}{3} + 0.25 \cdot \log_2 \frac{5}{2} \approx 0.198$$

→ 각각의 값이 다르므로
만족하지 않는데, 두 값은 서로 다르므로
주어진 값은 일차적으로 다른 배치를 보여준다
볼 수 있다.

2) KL Divergence의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

→ $D_{KL}(P||Q)$ 란 확률 P와 Q가 얼마나 근접한지,
값이 클수록 두 분포 P, Q가 많이 다르다는 뜻.

26-2 Part 1 과제

즉 $D_{KL}(P||Q) = 0$ 이 되려면 두 확률 분포가 모든 x에 대해
완전히 동일해야 한다.

3. Regression

3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 ($n=5$).

x	1	2	3	4	5
y	2	3	5	6	9

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

$$\bar{x} = \frac{1+2+3+4+5}{5} = 3 \quad S_{xy} = 6+2+0+1+8 = 17$$

$$\bar{y} = \frac{2+3+5+6+9}{5} = 5 \quad S_{yy} = 4+1+0+1+16 = 22$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

$$\hat{\beta}_1 = \frac{17}{10} = 1.7 \quad \hat{\beta}_0 = 5 - 5.1 = -0.1 \quad \rightarrow \hat{y} = -0.1 + 1.7x$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

$$SSE = 0.4^2 + (-0.3)^2 + 0^2 + (-0.1)^2 + 0.6^2 = 1.1 \quad R^2 = 1 - \frac{1.1}{22} = 0.9633$$

$$SST = (-3)^2 + (-2)^2 + 0^2 + 1^2 + 4^2 = 30$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

R^2 가 1에 가까워짐으로 이 회귀직선은 데이터를 96.33% 가량, 즉 매우 잘 설명하고 있다.

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해 X_1 의 VIF 를 계산하세요.

$$VIF_{X_1} = \frac{1}{1-R^2} = \frac{1}{0.1} = 10$$

2) 위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

VIF_{X_1} 이 10이므로 다중공선성이 큼.

$\rightarrow X_1$ 을 변수에서 제거 O.

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3,5,4)
Class B (○): (5,5), (5,3), (6,4)

새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN 으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요

$$\text{Class A: } (1,1), \frac{1}{2} \rightarrow d = \sqrt{(2-4)^2 + (4-4)^2}$$

$$\text{Class B: } (5,5), (5,3), (6,4) \rightarrow d = 2$$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

가장 가까운 이웃은 $(3,5,4)$, $(5,5)$, $(5,3)$
 $\downarrow \quad \downarrow \quad \downarrow$
 A B B $\rightarrow$ B

3) 거리의 역수 $w_i = \frac{1}{d(x_q, x_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

$$A (3,5,4) : \frac{1}{\frac{1}{2}} = 2$$

$$B (5,5) : \frac{1}{2}, (5,3) : \frac{1}{2} \rightarrow \text{가중치 합은 1로 2번은 } A$$

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

두 결과가 다르다.

KNN은 멀리 다수결이 다른 분류만,

weighted KNN은 가중치에 따라 포 하나씩의 영향을 본다.

즉 이웃들, 학습 데이터들 간의 거리 분포와 가중치에 따라 결과가 서로 다르게 나올 수 있다.

그리고 K값이 달라지면 선택할 이웃의 수가 달라진다

비교 결과가 모호한 경우가 속 있다.

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)

초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

$$\hookrightarrow C1 = \{P_1, P_2, P_3\}, C2 = \{P_4, P_5, P_6\}$$

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

$$C_1' = \left(\frac{2+2+3}{3}, \frac{3+1+2}{3} \right) = \left(\frac{7}{3}, 2 \right) \quad C_2' = \left(\frac{8+9+8}{3}, \frac{8+8+9}{3} \right) = \left(\frac{25}{3}, \frac{25}{3} \right)$$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

대부분 재배정 안됨, 이전 원의 등하게 배정 결과가 나옴.

→ 알고리즘 수렴 ○

5-2: DBSCAN

다음과 같은 2 차원 데이터에 $\text{eps} = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

$P_1(1,1)$, $P_2(1,2)$, $P_3(2,1)$, $P_4(2,2)$, $P_5(8,8)$, $P_6(8,9)$, $P_7(10,8)$, $P_8(9,8)$, $P_9(12,12)$

1) 각 점에 대해 eps 반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가 eps 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

$P_1: P_2, P_3, P_4$ 4개, $P_2: P_1, P_3, P_4$ 4개, $P_3: P_1, P_2, P_4$ 4개, $P_4: P_1, P_2, P_3$ 4개
 $P_5: P_6, P_8$ 3개, $P_6: P_5, P_8$ 2개, $P_7: P_8$ 2개, $P_8: P_5, P_6, P_7$ 4개
 $P_9: P_9$ 1개

2) minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

$P_1, P_2, P_3, P_4, P_5, P_6, P_8$ (core points)
 P_7 (border point)
 P_9 (noise point)

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

군집 1: P_1, P_2, P_3, P_4

군집 2: P_5, P_6, P_7, P_8

군집 3: P_9

군집의 개수를 미리 정해놓지 않아요,

데이터의 밀집도에 따라

알아서 군집을 생성하고 분해해주어요.

(eps 반경 안에 minPts 이상의 점이 있을 때)

Reference

- 26-2 Math for DS (15 기 김시원)
- 26-2 ML-supervised learning (15 기 조유빈)
- 26-2 ML-unsupervised learning (15 기 현승원)

Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원