

26-2 DSL 정규 세션

Part 1 과제



- ☑ 본 과제는 학회 정규 세션 「Math for DS」, 「ML-supervised learning」, 「ML-unsupervised learning」의 내용을 다루며, 개념의 적용과 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 해당 과제는 평가를 위한 것이 아니므로, 주어진 힌트(💡)를 적극 활용하시고 학회원 간 토론 및 Slack 질의응답을 적극 활용하여 해결해주시요. 단, **답안 표절이나 LLM의 남용은 금지합니다.**
- ☑ 8/8 (토) 23 시 59 분까지 Github 에 .PDF 파일 하나로 제출해주시요. Github 에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 적극적으로 활용해 주십시오.

1. Linear Algebra

1-1: 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1) A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(💡 힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.) $\det(A - \lambda I) = (4 - \lambda)(1 - \lambda) - 4 = \lambda^2 - 5\lambda = 0 \Rightarrow \lambda_1 = 0, \lambda_2 = 5$

i) $\lambda_1 = 0$ $Ax = 0$, $\begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}x = 0$, $x = (1, -2)$, $v_1 = (1/\sqrt{5}, -2/\sqrt{5})$

ii) $\lambda_2 = 5$ $(A - 5I)x = 0$, $\begin{bmatrix} -1 & 2 \\ 2 & -4 \end{bmatrix}x = 0$, $x = (2, 1)$, $v_2 = (2/\sqrt{5}, 1/\sqrt{5})$

2) 위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P는 직교행렬, D는 고윳값 대각행렬)

$$A = \begin{bmatrix} 2/\sqrt{5} & 1/\sqrt{5} \\ 1/\sqrt{5} & -2/\sqrt{5} \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 2/\sqrt{5} & 1/\sqrt{5} \\ 1/\sqrt{5} & -2/\sqrt{5} \end{bmatrix}$$

3) 고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

$$\lambda_1 = 0 \geq 0, \lambda_2 = 5 \geq 0 \rightarrow \text{모든 고윳값} \geq 0 \text{ 이므로 PSD}$$

4) (Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

1-2: 특잇값 분해

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} \quad B^T = \begin{bmatrix} 2 & 1 & 2 \\ 2 & -1 & 2 \end{bmatrix}$$

1) B^TB (2×2)와 BB^T (3×3)를 각각 계산하세요. $B^TB = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix}$

$$BB^T = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}$$

2) B^TB 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해

특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$) $\det(B^TB - \lambda I) = (9-\lambda)^2 - 49 = 0 \rightarrow \lambda_1 = 16, \lambda_2 = 2$
 $\sigma_1 = 4, \sigma_2 = \sqrt{2}$

i) $\lambda_1 = 16$ $(B^TB - 16I)v = 0$, $\begin{bmatrix} -7 & 7 \\ 7 & -7 \end{bmatrix}v = 0$, $v = (1, 1) \rightarrow v_1 = \frac{1}{\sqrt{2}}(1, 1)$

ii) $\lambda_2 = 2$ $(B^TB - 2I)v = 0$, $\begin{bmatrix} 7 & 7 \\ 7 & 7 \end{bmatrix}v = 0$, $v = (1, -1) \rightarrow v_2 = \frac{1}{\sqrt{2}}(1, -1)$

$$\therefore V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

3) BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3 개

나오며, 그중 가장 작은 고윳값은 0 이 됩니다.) $\det(BB^T - \lambda I) = (2-\lambda)\lambda(\lambda-16) = 0 \rightarrow \lambda_1 = 16, \lambda_2 = 2, \lambda_3 = 0$

i) $\lambda_1 = 16$ $(BB^T - 16I)u = 0$, $u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$

ii) $\lambda_2 = 2$ $(BB^T - 2I)u = 0$, $u_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$

iii) $\lambda_3 = 0$ $BB^T u = 0$, $u_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$

$$\therefore U = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

4) 위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U\Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0 인 3×2 직사각 대각행렬입니다.)

$$\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

$$B = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

1-3: 주성분 분석(PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}$$

1) Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요. $\det(\Sigma - \lambda I) = (5 - \lambda)^2 - 9 = 0 \rightarrow \lambda_1 = 8, \lambda_2 = 2$
i) $\lambda_1 = 8$ $(\Sigma - 8I)v = 0$, $v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

ii) $\lambda_2 = 2$ $(\Sigma - 2I)v = 0$, $v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$

2) 위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.

(💡 힌트: PCA에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

$$PC1 (\lambda = 8) : \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$PC2 (\lambda = 2) : \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

3) 각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

$$PC1 : \frac{8}{8+2} = \frac{8}{10} = 80\%$$

$$PC2 : \frac{2}{8+2} = \frac{2}{10} = 20\%$$

4) 위의 결과를 근거로, 이 데이터를 1 차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

PC1만으로 축소했을 때 설명되지 않는 분산은 20%이고, 전체 분산의 80%를 유지하므로 정보 손실이 크지 않아 1차원 축소가 합리적이다.

2. Information Theory

2-1: Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16 개입니다.)

클래스	개수
A	8
B	4
C	4

1) 각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요

$$P(A) = \frac{8}{16} = \frac{1}{2}, \quad P(B) = \frac{4}{16} = \frac{1}{4}, \quad P(C) = \frac{1}{4}$$

2) 클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요. $H(X) = -\sum_x P(x) \log_2 P(x)$

$$H(X) = -\left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{4} \log_2 \frac{1}{4} + \frac{1}{4} \log_2 \frac{1}{4}\right) = -\left(-\frac{1}{2} - \frac{1}{2} - \frac{1}{2}\right) = 1.5 \text{ bits}$$

3) 엔트로피의 최댓값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(💡 힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

$$\text{클래스 3개가 균등분포일 때 최대 엔트로피 } H_{\max} = \log_2 3 \approx 1.585 \text{ bits}$$

$$\text{현재 } \frac{1.5}{1.585} \approx 94.6\% \text{ 로 최댓값에 가까워 불확실성이 높은 분포}$$

2-2: KL-Divergence

두 확률 분포 P 와 Q 가 다음과 같이 주어졌습니다.

X	A	B	C
$P(X)$	0.5	0.3	0.2
$Q(X)$	0.25	0.5	0.25

1) $D_{KL}(P||Q)$ 와 $D_{KL}(Q||P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence가

거리(distance)의 정의를 만족하지 않는 이유를 설명하세요. $D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$

$$D_{KL}(P||Q) = 0.5 \times \log_2 \frac{0.5}{0.25} + 0.3 \times \log_2 \frac{0.3}{0.5} + 0.2 \times \log_2 \frac{0.2}{0.25} \approx 0.215 \text{ bits}$$

$$D_{KL}(Q||P) = 0.25 \times \log_2 \frac{0.25}{0.5} + 0.5 \times \log_2 \frac{0.5}{0.3} + 0.25 \times \log_2 \frac{0.25}{0.2} \approx 0.199 \text{ bits}$$

거리는 대칭성 $d(x, y) = d(y, x)$ 만족해야 하므로 KL-divergence는 거리 아님

2) KL Divergence의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P||Q) = 0$ 이 되는 조건을 설명하세요.

KL-divergence는 참 분포 P 를 근사 분포 Q 로 표현할 때 발생하는 정보 손실량을 측정

$D_{KL}(P||Q) = 0 \Leftrightarrow$ 모든 x 에 대해 $P(x) = Q(x)$, 즉 두 분포가 완전히 동일할 때만 0이 됨

3. Regression

3-1: 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 (n=5).

x	y	$\hat{y}$	e	e^2
1	2	1.6	0.4	0.16
2	3	3.3	-0.3	0.09
3	5	5.0	0	0
4	6	6.7	-0.7	0.49
5	9	8.4	0.6	0.36

x	1	2	3	4	5
y	2	3	5	6	9

1) $\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요. $\bar{x}=3, \bar{y}=5$

$$S_{xy} = 6 + 2 + 0 + 1 + 8 = 17$$

$$S_{xx} = 4 + 1 + 0 + 1 + 4 = 10$$

2) $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

$$\hat{\beta}_1 = \frac{17}{10} = 1.7, \hat{\beta}_0 = 5 - 1.7 \times 3 = -0.1 \rightarrow \therefore \hat{y} = -0.1 + 1.7x$$

3) 각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

$$SSE = 1.1, SST = 9 + 4 + 0 + 1 + 16 = 30$$

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.1}{30} = 0.9633$$

4) 계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

$R^2 \approx 0.963$ 으로, 회귀직선이 전체 분산의 약 96.3%를 잘 설명

매우 높은 설명력으로, x 와 y 사이 강한 선형관계

3-2: 다중공선성 & VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9 로 계산되었습니다.

1) VIF 공식을 이용해 X_1 의 VIF 를 계산하세요.

$$VIF(X_1) = \frac{1}{1-R^2} = \frac{1}{1-0.9} = 10$$

2) 위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

VIF=10은 일반적인 기준에서 심각한 다중공선성을 나타낸다.

X_1 이 X_2 와 X_3 로 거의 설명되므로, 변수 제거 또는 정규화(Ridge 등)를 고려해야 한다.

4. Classification

4-1: KNN

2 차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1,1), (3.5,4)
Class B (○): (5,5), (5,3), (6,4)

새로운 데이터 $q=(4,4)$ 에 대해 $K=3$ 인 KNN 으로 분류하고자 합니다.

1) q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요 $(1,1) : 3\sqrt{2} \approx 4.243, (3.5,4) : 0.5$
 $(5,5) : \sqrt{2} \approx 1.414, (5,3) : \sqrt{2} \approx 1.414, (6,4) : 2$

2) 가장 가까운 3 개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

가까운 순 $(3.5, 4) \rightarrow (5, 5) \rightarrow (5, 3)$
단순 다수결 $\rightarrow$ Class B

3) 거리의 역수 $w_i = \frac{1}{d(X_q, X_i)}$ 를 가중치로 사용하는 weighted KNN 을 이용해 다시 예측하세요.

(💡 힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다.

이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.) $(3.5, 4) : \text{가중치 } 2.0$

$(5, 5) : \text{가중치 } \approx 0.707, (5, 3) : \text{가중치 } \approx 0.707$

A 가중치 합 = 2.0 , B 가중치 합 = $0.707 + 0.707 = 1.414 \rightarrow$ Class A

4) 단순 다수결과 weighted KNN 의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

단순 다수결은 B, 가중 KNN은 A로 결과가 다르다.

(3.5,4)가 $d=0.5$ 로 압도적으로 가까운데, 단순 다수결에서는 이 거리 차이가 반영되지 않는다.

가중 KNN에서는 가까운 이웃의 영향력이 커져 A가 역전된다.

5. Clustering

5-1: K-means 클러스터링

다음과 같은 2 차원 데이터가 주어져 있습니다 (K=2)

P1 (2, 3), P2 (2, 1), P3 (3, 2), P4 (8, 8), P5 (9, 8), P6 (8, 9)
초기 centroid: C1 = (2, 3), C2 = (8, 8)

1) 유클리드 거리를 기준으로 각 점을 가장 가까운 centroid 에 배정하세요.

P_1 부터 P_6 까지 순서대로 $C_1, C_1, C_1, C_2, C_2, C_2$

2) 배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

$$C_1' = \left(\frac{2+2+3}{3}, \frac{3+1+2}{3} \right) = \left(\frac{7}{3}, 2 \right), \quad C_2' = \left(\frac{8+9+8}{3}, \frac{8+8+9}{3} \right) = \left(\frac{25}{3}, \frac{25}{3} \right)$$

3) 갱신된 centroid 로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

갱신된 centroid 로 재배정해도 P1~P3는 C1, P4~P6는 C2로 동일 -> 수렴

5-2: DBSCAN

다음과 같은 2 차원 데이터에 $\text{eps} = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

$P1(1,1)$, $P2(1,2)$, $P3(2,1)$, $P4(2,2)$, $P5(8,8)$, $P6(8,9)$, $P7(10,8)$, $P8(9,8)$, $P9(12,12)$

1) 각 점에 대해 eps 반경 내 이웃의 개수를 계산하세요. (💡 힌트: 두 점 사이의 거리가 eps 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

P_1 부터 P_9 까지 순서대로 4, 4, 4, 4, 3, 3, 2, 4, 1 개. ($d \leq 1.5$)

2) minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

core point (이웃 ≥ 3) : $P1, P2, P3, P4, P5, P6, P8$

border point (이웃 < 3 이지만 core 의 eps 내) : $P7$

noise point : $P9$

3) 위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN 이 K-means 와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

cluster 1 : $\{P1, P2, P3, P4\}$

cluster 2 : $\{P5, P6, P7, P8\}$

Noise : $\{P9\}$

DBSCAN은 밀도 기반으로 core point 간의 연결을 통해 자동으로 군집이 형성되므로, K-means처럼 군집 수 K를 사전에 지정할 필요가 없다.
또한 노이즈를 자연스럽게 분리할 수 있다는 장점이 있다.

Reference

- 26-2 Math for DS (15 기 김시원)
- 26-2 ML-supervised learning (15 기 조유빈)
- 26-2 ML-unsupervised learning (15 기 현승원)

Data Science Lab

담당자: 15 기 안재민, 이은민, 현승원