

26-2 DSL 정규 세션: Part 1 과제 풀이

Linear Algebra · Information Theory · Regression · Classification · Clustering

1 Linear Algebra

1.1 고윳값 분해

다음과 같은 대칭행렬 A 가 주어져 있습니다.

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 1 \end{bmatrix}$$

1. 문제

A 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

(힌트: 특성방정식 $\det(A - \lambda I) = 0$ 을 먼저 구한 뒤, 각 고윳값에 대해 $(A - \lambda I)x = 0$ 을 풀어 고유벡터를 구하세요.)

풀이

특성방정식은

$$\det(A - \lambda I) = \begin{vmatrix} 4 - \lambda & 2 \\ 2 & 1 - \lambda \end{vmatrix} = (4 - \lambda)(1 - \lambda) - 4 = \lambda(\lambda - 5) = 0.$$

따라서 eigenvalue는 $\lambda_1 = 5$, $\lambda_2 = 0$ 이다.

$\lambda_1 = 5$ 일 때 $-x + 2y = 0$ 이므로 $x = 2y$ 이고, $\lambda_2 = 0$ 일 때 $2x + y = 0$ 이므로 $y = -2x$ 이다. 한 가지 unit eigenvector 선택은

$$p_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad p_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ -2 \end{bmatrix}.$$

두 벡터는 $p_1^T p_2 = 0$ 이고 각각 norm이 1이다. (각 eigenvector의 부호를 바꾸어도 같은 답이다.)

2. 문제

위 결과를 이용해 A 를 $A = PDP^T$ 형태로 대각화하세요. (P 는 직교행렬, D 는 고윳값 대각행렬)

풀이

위 순서대로 column을 배치하면

$$P = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix}, \quad D = \begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}, \quad P^T P = I.$$

그러므로 spectral decomposition은

$$\boxed{A = PDP^T}$$

이며 실제로 $PDP^T = 5p_1p_1^T = A$ 이다.

3. 문제

고윳값을 이용하여 A 가 PD, PSD, ND, NSD 중 무엇인지 판별하세요.

풀이

모든 eigenvalue가 nonnegative이고 0인 eigenvalue가 존재한다. 따라서

A 는 positive semidefinite (PSD)이다.

$x = p_2 \neq 0$ 에 대해 $x^T A x = 0$ 이므로 positive definite (PD)는 아니다.

4. 문제

(Optional) A 가 대칭행렬이 아니라 일반 정사각행렬이었다면, 고유벡터들이 서로 직교(orthogonal)한다는 보장이 없는 이유를 설명하고, 실수인 대칭행렬에서만 직교대각화가 항상 가능한 이유를 서술하세요.

풀이

일반 square matrix는 normal matrix일 필요가 없으므로 서로 다른 eigenvalue에 대응하는 eigenvector라도 orthogonal하다는 보장이 없다. 예를 들어 $\begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 의 eigenvector로 $(1, 0)^T$, $(1, 1)^T$ 를 잡을 수 있는데 둘은 orthogonal하지 않다. 반면 real symmetric matrix는 spectral theorem에 의해 모든 eigenvalue가 real이고, 서로 다른 eigenvalue의 eigenspace들이 서로 orthogonal하다. 같은 eigenvalue의 eigenspace 안에서도 Gram-Schmidt로 orthonormal basis를 고를 수 있으므로 항상 orthogonal diagonalization $A = PDP^T$ 가 가능하다.

1.2 특잇값 분해 (SVD)

다음과 같은 행렬 B 가 주어져 있습니다.

$$B = \begin{bmatrix} 2 & 2 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}.$$

1. 문제

$B^T B$ (2×2)와 BB^T (3×3)를 각각 계산하세요.

풀이

직접 곱하면

$$B^T B = \begin{bmatrix} 9 & 7 \\ 7 & 9 \end{bmatrix}, \quad BB^T = \begin{bmatrix} 8 & 0 & 8 \\ 0 & 2 & 0 \\ 8 & 0 & 8 \end{bmatrix}.$$

2. 문제

$B^T B$ 의 고윳값과 (단위)고유벡터를 구하여 V 를 구성하고, 이 고윳값의 제곱근을 이용해 특잇값(singular values) σ_1, σ_2 를 구하세요. ($\sigma_1 > \sigma_2$)

풀이

$B^T B$ 의 characteristic polynomial은

$$\det(B^T B - \lambda I) = (9 - \lambda)^2 - 49 = (\lambda - 16)(\lambda - 2).$$

eigenvalue를 큰 순서로 배열하면 16, 2이고, 대응하는 unit eigenvector는

$$v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

따라서

$$V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \boxed{\sigma_1 = 4, \quad \sigma_2 = \sqrt{2}}.$$

3. 문제

BB^T 의 고윳값과 (단위)고유벡터를 구하여 U 를 구성하세요. (BB^T 는 3×3 이므로 고윳값이 3개 나오며, 그중 가장 작은 고윳값은 0이 됩니다.)

풀이

BB^T 의 eigenvalue는 16, 2, 0이다. $u_i = Bv_i/\sigma_i$ 를 이용하면

$$u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad u_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

null space 방향의 unit vector $u_3 = \frac{1}{\sqrt{2}}(1, 0, -1)^T$ 를 추가하면

$$U = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix}.$$

4. 문제

위에서 구한 U (3×3), Σ (3×2), V (2×2)를 이용해 $B = U\Sigma V^T$ 형태로 명시하세요. (Σ 는 주대각원소가 σ_1, σ_2 이고 나머지는 0인 3×2 직사각 대각행렬입니다.)

풀이

직사각 diagonal matrix를

$$\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

로 두면 full SVD는

$$B = \begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

이다. 여기서 마지막 행렬은 V^T 이며, 이 예에서는 선택한 V 가 symmetric이어서 $V^T = V$ 이다.

1.3 주성분 분석 (PCA)

어떤 데이터셋의 공분산행렬 Σ 가 다음과 같이 계산되었습니다.

$$\Sigma = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}.$$

1. 문제

Σ 의 고윳값과 각 고윳값에 대응하는 단위 고유벡터를 구하세요.

풀이

$$\det(\Sigma - \lambda I) = (5 - \lambda)^2 - 9 = (\lambda - 8)(\lambda - 2),$$

이므로 eigenvalue와 unit eigenvector를 큰 순서로 쓰면

$$\lambda_1 = 8, \quad v_1 = \frac{1}{\sqrt{2}}(1, 1)^T; \quad \lambda_2 = 2, \quad v_2 = \frac{1}{\sqrt{2}}(1, -1)^T.$$

2. 문제

위 결과를 이용해 제 1 주성분(PC1)과 제 2 주성분(PC2)의 방향벡터(주성분 축)를 각각 명시하세요.
(힌트: PCA에서는 가장 큰 고윳값에 대응하는 고유벡터가 제 1 주성분(PC1)이며, 두 번째로 큰 고윳값에 대응하는 고유벡터가 제 2 주성분(PC2)입니다.)

풀이

따라서 $\boxed{PC1 = v_1}$, $\boxed{PC2 = v_2}$ 이다. 벡터의 부호를 반대로 잡아도 같은 principal axis를 나타낸다.

3. 문제

각 주성분이 설명하는 분산의 비율(explained variance ratio)을 계산하세요.

풀이

Total variance는 $\text{tr}(\Sigma) = 8 + 2 = 10$ 이므로

$$\text{EVR}_{PC1} = \frac{8}{10} = 0.8 = 80\%, \quad \text{EVR}_{PC2} = \frac{2}{10} = 0.2 = 20\%.$$

4. 문제

위의 결과를 근거로, 이 데이터를 1차원(PC1)만으로 축소했을 때 설명되지 않는 분산의 비율이 어느 정도일지 판단하고, 그 판단의 근거를 설명하세요.

풀이

PC1만 남기면 설명되지 않는 variance는 PC2가 담당하는 $\boxed{20\%}$ 이다. 즉 dimension을 2에서 1로 줄이면서 전체 variance의 80%를 보존하고 20%를 잃는다.

2 Information Theory

2.1 Entropy

어떤 데이터셋에서 클래스의 분포가 다음과 같이 주어졌습니다. (총 데이터의 개수는 16개입니다.)

클래스	개수
A	8
B	4
C	4

1. 문제

각 클래스의 발생확률 $P(A)$, $P(B)$, $P(C)$ 를 구하세요.

풀이

총 16개이므로

$$P(A) = \frac{8}{16} = \frac{1}{2}, \quad P(B) = P(C) = \frac{4}{16} = \frac{1}{4}.$$

2. 문제

클래스 분포의 엔트로피(Entropy)를 다음 식을 이용하여 계산하세요.

$$H(X) = - \sum_x P(x) \log_2 P(x)$$

풀이

단위를 bit로 두면

$$\begin{aligned} H(X) &= - \sum_x P(x) \log_2 P(x) \\ &= - \left(\frac{1}{2} \log_2 \frac{1}{2} + 2 \cdot \frac{1}{4} \log_2 \frac{1}{4} \right) = \boxed{1.5 \text{ bits}}. \end{aligned}$$

3. 문제

엔트로피의 최대값은 얼마이며, 현재 데이터의 엔트로피와 비교하여 데이터의 불확실성을 해석하세요.

(힌트: 최대 엔트로피는 모든 클래스의 확률이 동일할 때 발생합니다.)

풀이

세 class가 uniform distribution일 때 maximum entropy는

$$H_{\max} = \log_2 3 \approx \boxed{1.585 \text{ bits}}.$$

현재 entropy는 최대값의 약 $1.5/1.585 \approx 94.6\%$ 로 상당히 높다. 다만 class A의 비율이 더 커서 완전한 uniform case보다 uncertainty가 조금 낮다.

2.2 KL-Divergence

두 확률 분포 P 와 Q 가 다음과 같이 주어졌습니다.

X	A	B	C
$P(X)$	0.5	0.3	0.2
$Q(X)$	0.25	0.5	0.25

1. 문제

$D_{KL}(P\|Q)$ 와 $D_{KL}(Q\|P)$ 를 각각 구하고, 두 값이 다르다는 것을 통해 KL-divergence가 거리(distance)의 정의를 만족하지 않는 이유를 설명하세요.

$$D_{KL}(P\|Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$$

풀이

$$\begin{aligned} D_{KL}(P\|Q) &= 0.5 \log_2 \frac{0.5}{0.25} + 0.3 \log_2 \frac{0.3}{0.5} + 0.2 \log_2 \frac{0.2}{0.25} \\ &\approx \boxed{0.2145 \text{ bits}}, \\ D_{KL}(Q\|P) &= 0.25 \log_2 \frac{0.25}{0.5} + 0.5 \log_2 \frac{0.5}{0.3} + 0.25 \log_2 \frac{0.25}{0.2} \\ &\approx \boxed{0.1990 \text{ bits}}. \end{aligned}$$

두 값이 다르므로 KL-divergence는 symmetric하지 않다. 따라서 metric이 만족해야 하는 $d(P, Q) = d(Q, P)$ 를 위반하여 일반적인 distance가 아니다. (또한 triangle inequality도 일반적으로 만족하지 않는다.)

2. 문제

KL Divergence의 의미를 간단히 설명하세요. 그리고 $D_{KL}(P\|Q) = 0$ 이 되는 조건을 설명하세요.

풀이

$D_{KL}(P\|Q)$ 는 실제 distribution이 P 인데 Q 로 근사하거나 encoding할 때 생기는 expected information loss 또는 extra code length를 나타낸다. Gibbs' inequality에 의해 항상 non-negative이고, discrete distribution에서는 P 가 양의 확률을 주는 모든 곳에서 $P(x) = Q(x)$ 일 때, 즉 두 분포가 (거의 모든 곳에서) 같을 때에만 $D_{KL}(P\|Q) = 0$ 이다.

3 Regression

3.1 단순 선형 회귀

다음과 같은 데이터가 주어져 있습니다 ($n = 5$).

x	1	2	3	4	5
y	2	3	5	6	9

1. 문제

$\bar{x}$, $\bar{y}$ 를 구하고, $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 를 계산하세요.

풀이

$$\begin{aligned} \bar{x} &= 3, & \bar{y} &= 5, \\ S_{xy} &= (-2)(-3) + (-1)(-2) + 0 \cdot 0 + 1 \cdot 1 + 2 \cdot 4 = 17, \\ S_{xx} &= (-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2 = 10. \end{aligned}$$

2. 문제

$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ 공식을 이용해 회귀직선 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 을 구하세요.

풀이

$$\hat{\beta}_1 = \frac{17}{10} = 1.7, \quad \hat{\beta}_0 = 5 - (1.7)(3) = -0.1.$$

따라서 regression line은 $\hat{y} = -0.1 + 1.7x$ 이다.

3. 문제

각 관측치의 잔차 $e_i = y_i - \hat{y}_i$ 와, $SSE = \sum_{i=1}^n e_i^2$, $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ 를 계산해 R^2 을 구하세요.

풀이

예측값과 residual은 다음과 같다.

x_i	1	2	3	4	5
y_i	2	3	5	6	9
$\hat{y}_i$	1.6	3.3	5.0	6.7	8.4
$e_i = y_i - \hat{y}_i$	0.4	-0.3	0	-0.7	0.6

따라서

$$SSE = 0.4^2 + (-0.3)^2 + 0^2 + (-0.7)^2 + 0.6^2 = 1.10,$$

$$SST = (-3)^2 + (-2)^2 + 0^2 + 1^2 + 4^2 = 30,$$

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{1.1}{30} = \boxed{0.9633 \text{ (96.33\%)}}.$$

4. 문제

계산된 R^2 값을 근거로 이 회귀직선이 데이터를 얼마나 잘 설명하는지 평가하세요.

풀이

이 표본에서는 y variation의 약 96.3%를 선형 관계로 설명하므로 fit이 매우 좋다. 다만 $n = 5$ 로 작고 R^2 만으로 linearity, outlier, error independence 및 generalization을 보장할 수 없으므로 residual diagnostics와 validation도 함께 확인해야 한다.

3.2 다중공선성 및 VIF

세 개의 입력변수 X_1, X_2, X_3 를 가진 다중선형회귀 모형에서, X_1 을 나머지 두 변수(X_2, X_3)로 회귀했을 때의 R^2 이 0.9로 계산되었습니다.

1. 문제

VIF 공식을 이용해 X_1 의 VIF를 계산하세요.

풀이

$$VIF_{X_1} = \frac{1}{1 - R_1^2} = \frac{1}{1 - 0.9} = \boxed{10}.$$

2. 문제

위 결과를 근거로 X_1 의 다중공선성 수준을 평가하고, 변수 제거 여부에 대해 설명하세요.

풀이

흔히 VIF 5 이상을 주의, 10 이상을 severe multicollinearity의 기준으로 사용하므로 X_1 의 coefficient variance가 크게 inflation된 상태이다. 그러나 VIF만으로 즉시 변수를 제거하면 안 된다. X_1 의 domain importance, coefficient의 목적(interpretation인지 prediction인지), standard error, 다른 변수의 VIF를 함께 검토해야 한다. 필요하면 중복 변수를 제거·결합하거나 regularization (ridge 등)을 적용할 수 있다.

4 Classification: KNN

2차원 평면에 다음과 같은 학습 데이터가 주어져 있습니다.

Class A (●): (1, 1), (3.5, 4)
Class B (○): (5, 5), (5, 3), (6, 4)

새로운 데이터 $q = (4, 4)$ 에 대해 $K = 3$ 인 KNN으로 분류하고자 합니다.

1. 문제

q 와 각 학습 데이터 간의 유클리드 거리를 계산하세요.

풀이

Point	Class	Distance from q	Approx.
(1, 1)	A	$\sqrt{(4-1)^2 + (4-1)^2} = \sqrt{18}$	4.243
(3.5, 4)	A	$\sqrt{0.5^2} = 0.5$	0.500
(5, 5)	B	$\sqrt{1^2 + 1^2} = \sqrt{2}$	1.414
(5, 3)	B	$\sqrt{1^2 + (-1)^2} = \sqrt{2}$	1.414
(6, 4)	B	$\sqrt{2^2} = 2$	2.000

2. 문제

가장 가까운 3개의 이웃을 찾고, 단순 다수결로 q 의 클래스를 예측하세요.

풀이

가장 가까운 세 neighbor는 A의 (3.5, 4)와 B의 (5, 5), (5, 3)이다. 단순 majority vote는 A 1표, B 2표이므로 $q \rightarrow \text{Class B}$ 이다.

3. 문제

거리의 역수 $w_i = \frac{1}{d(X_q, X_i)}$ 를 가중치로 사용하는 weighted KNN을 이용해 다시 예측하세요.

(힌트: 유클리드 거리를 이용해 가장 가까운 K 개의 이웃을 선택한 뒤, 각 이웃의 가중치를 계산합니다. 이후 각 클래스의 가중치 합을 비교하여 가장 큰 클래스로 분류합니다.)

풀이

inverse-distance weight를 합하면

$$W_A = \frac{1}{0.5} = 2, \quad W_B = \frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} = \sqrt{2} \approx 1.414.$$

따라서 weighted KNN은 $q \rightarrow \text{Class A}$ 로 예측한다.

4. 문제

단순 다수결과 weighted KNN의 결과를 비교하고, 두 결과가 같은지 다른지, 그리고 그 이유를 K 값 및 이웃과의 거리 분포 관점에서 설명하세요.

풀이

결과는 서로 다르다. $K = 3$ 의 majority vote에서는 B neighbor 두 개가 수적으로 우세하지만, A neighbor 하나가 거리 0.5로 매우 가까워 weighted vote에서는 그 하나의 영향력 2가 두 B neighbor의 합보다 커진다.

5 Clustering

5.1 K-means clustering

다음과 같은 2차원 데이터가 주어져 있습니다 ($K = 2$)

$$P_1(2, 3), P_2(2, 1), P_3(3, 2), P_4(8, 8), P_5(9, 8), P_6(8, 9) \\ \text{초기 centroid: } C_1 = (2, 3), C_2 = (8, 8)$$

1. 문제

유클리드 거리를 기준으로 각 점을 가장 가까운 centroid에 배정하세요.

풀이

초기 centroid까지의 거리는 다음과 같다.

Point	$d(C_1)$	$d(C_2)$	Assignment
$P_1(2, 3)$	0	$\sqrt{61}$	1
$P_2(2, 1)$	2	$\sqrt{85}$	1
$P_3(3, 2)$	$\sqrt{2}$	$\sqrt{61}$	1
$P_4(8, 8)$	$\sqrt{61}$	0	2
$P_5(9, 8)$	$\sqrt{68}$	1	2
$P_6(8, 9)$	$\sqrt{72}$	1	2

따라서 $C_1 = \{P_1, P_2, P_3\}$, $C_2 = \{P_4, P_5, P_6\}$ 이다.

2. 문제

배정 결과를 바탕으로 각 군집의 새로운 centroid(평균)를 계산하세요.

풀이

새로운 centroid는 각 cluster의 coordinate-wise mean이다.

$$C'_1 = \left(\frac{2+2+3}{3}, \frac{3+1+2}{3} \right) = \left(\frac{7}{3}, 2 \right)$$

$$C'_2 = \left(\frac{8+9+8}{3}, \frac{8+8+9}{3} \right) = \left(\frac{25}{3}, \frac{25}{3} \right)$$

3. 문제

갱신된 centroid로 재배정을 수행하고, 이전 배정 결과와 비교하여 알고리즘이 수렴했는지 판단하세요.

풀이

갱신 후 거리의 approximate value는 다음과 같다.

Point	$d(C'_1)$	$d(C'_2)$	Reassignment
P_1	1.054	8.280	1
P_2	1.054	9.690	1
P_3	0.667	8.280	1
P_4	8.253	0.471	2
P_5	8.970	0.745	2
P_6	9.006	0.745	2

assignment가 바뀌지 않았으므로 다음 centroid update도 동일하다. 따라서 algorithm은 이 단계에서 **converged**이다.

5.2 DBSCAN

다음과 같은 2차원 데이터에 $\text{eps} = 1.5$, $\text{minPts} = 3$ 을 적용합니다.

$$P_1(1, 1), P_2(1, 2), P_3(2, 1), P_4(2, 2), P_5(8, 8), \\ P_6(8, 9), P_7(10, 8), P_8(9, 8), P_9(12, 12)$$

1. 문제

각 점에 대해 eps 반경 내 이웃의 개수를 계산하세요. (힌트: 두 점 사이의 거리가 eps 이하이면 이웃으로 간주합니다. 자기 자신도 이웃의 개수에 포함합니다.)

풀이

각 ε -neighborhood는

$$\begin{aligned} N(P_1) &= N(P_2) = N(P_3) = N(P_4) = \{P_1, P_2, P_3, P_4\}, \\ N(P_5) &= \{P_5, P_6, P_8\}, \\ N(P_6) &= \{P_5, P_6, P_8\}, \\ N(P_7) &= \{P_7, P_8\}, \\ N(P_8) &= \{P_5, P_6, P_7, P_8\}, \\ N(P_9) &= \{P_9\}. \end{aligned}$$

따라서 neighborhood count는 차례대로

$$(4, 4, 4, 4, 3, 3, 2, 4, 1).$$

2. 문제

minPts 기준을 이용해 각 점을 core point, border point, noise point 중 하나로 분류하세요.

풀이

$|N(P_i)| \geq 3$ 이면 core point이다. 따라서

$$\begin{aligned} \text{Core:} & \quad P_1, P_2, P_3, P_4, P_5, P_6, P_8, \\ \text{Border:} & \quad P_7 \quad (\text{core } P_8 \text{의 neighborhood 안}), \\ \text{Noise:} & \quad P_9. \end{aligned}$$

3. 문제

위 분류 결과를 바탕으로 최종 군집을 구성하고, DBSCAN이 K-means와 달리 군집의 개수를 사전에 지정하지 않아도 되는 이유를 설명하세요.

풀이

density-reachability에 따라 최종 cluster는

$$\mathcal{C}_1 = \{P_1, P_2, P_3, P_4\}, \quad \mathcal{C}_2 = \{P_5, P_6, P_7, P_8\},$$

이고 P_9 는 noise이다. DBSCAN은 ε 와 minPts로 정의되는 dense region에서 core point를 시작으로 density-connected point를 확장한다. 따라서 cluster 수는 이 연결 성분의 수로 data에서 결정되며, K-means처럼 K 를 미리 정할 필요가 없다.

계산값은 base-2 logarithm과 Euclidean distance를 기준으로 하였다.